【论文翻译】——Constitutional Rights in the Machine-Learning State

Aziz Z. Huq, *Constitutional Rights in the Machine-Learning State*, 105 Cornell Law Review 1875 (2020).

摘要：

一类新型的“机器学习”工具能够从数据中生成据称比以往更为精准的预测与推断，其能力之强已超出此前的想象。对国家而言，机器学习是一种强大而灵活的手段，可用于揭示公民隐藏的信念、行为及预期行动。然而，当政府运用此类工具向特定个体分配调查资源、福利给付或施加强制性惩罚时，便可能触及正当程序、隐私与平等权益。

然而，当前保障这些权益的实体性法律框架与执行机制，均是在人类行为的背景下发展起来的，并未针对机器学习的情境进行专门设计。本文旨在开启一项更宏大的工程：构建一套适用于“机器学习国家”（machine-learning state）的实体规则与执法机制，以切实促进正当程序、隐私与平等价值。

通过梳理州及地方政府采用机器学习工具的典型实例，本文探讨了现有宪法规范如何在机器学习语境下被重新调适——就正当程序与平等原则而言，需进行“再校准”（recalibrated）；就隐私权而言，则需“重构”（retooled）。此外，本文还重新审视了宪法权益的执行机制，以回应机器学习日益普及所带来的挑战。

当前，宪法权利主要（且很大程度上）通过分散的、个案式的法律诉讼来实施。然而，机器学习所引发的规范性问题，源于系统性的设计选择，而非孤立的个体错误。因此，目前主导宪法救济领域的“零售式”（retail）执法机制尤为不适用。

取而代之的，应是一种审慎结合的事前规制（ex ante regulation）与事后集体诉讼（ex post aggregate litigation）的混合模式。二者互为必要补充，方能有效应对机器学习时代对基本权利构成的系统性挑战。

目录

介绍
一、治理中的机器学习转向
A. 预测与推断的新工具 1885
B. 机器学习国家 1890
1. 机器学习与监管型国家 1892
2. 机器学习与分配型国家 1894
3. 机器学习与惩罚型国家：以人脸识别为案例 1899
二、在机器学习国家中适用宪法价值..... 1905
A. 程序性正当程序 1905
1. 程序性正当程序规范 1907
2. 在机器学习中的适用 1908
3. 以正当程序规范检验算法设计 1910
4. 马修斯案 与机器学习 1915
B. 平等与反歧视规范 1917
1. 平等保护规范 1918
2. 将平等保护原则适用于机器学习 1919
3. 对机器学习与平等的再思考 1923
C. 隐私 1927
1. 宪法隐私规范 1927
2. 机器学习带来的隐私风险 1929
3. 机器学习国家中的隐私权 1931
D. 机器学习的宪法规范：小结 1937
三、机器学习国家中的宪法救济机制..... 1938
A. 算法规制 1940
1. 实体性规制干预 1941
2. 透明度与披露义务 1943
B. 算法合宪性的司法诉讼 1948
结论 1952

介绍

一种对国家的深刻怀疑精神，构成了美国宪政主义的核心。[1] 美国宪政主义追求法治之下的政府治理，其目标是在使国家能够促进公共福祉的同时，遏制国家对个人权利所构成的风险。[2] 技术调节着这一权衡关系。[3] 国家塑造其公民生活的能力——无论为善或为恶——历来取决于其所掌握的工具。[4] （技术决定法律制度的实际效果）

如今，正在改变国家行为方式的一种技术，是一类被称为“机器学习”（machine learning）的计算工具。这些工具以崭新的方式生成预测与推断，往往利用大量原本几乎无法解读的数据池。[5] 许多人最初是在市场中接触到机器学习工具的。例如，Facebook 使用它们来判断哪种“标题党”内容最具诱惑力；亚马逊则用它们预测你可能购买哪些商品。[6]

但在国家手中，机器学习工具所做的远不止推荐膳食补充剂或时尚配饰。相反，它们能够挖掘此前价值较低的数据——例如行政记录、刑事司法记录或公共监控录像——从而对人们的信念、行为及未来可能的行为产生令人震惊的洞察。

试想一些当前和未来的应用场景。公共监控摄像头通常会产生数千小时的录像素材。这远远超出了人工审查的能力，除非事先有非常具体的调查线索。机器学习工具可以低成本地被训练用于分析大量录像，并通过分析在极短的时间和人力投入下识别人脸或行为模式。[7]

在另一情境中，新型计算工具可被训练用于分析一个人握持和滑动手机的方式，从而唯一地识别该用户。[8] 商业银行已开始使用此类生物特征签名来实现远程账户访问。[9] 不久的将来，政府很可能也会采用相同的功能。（算法会在大量的环节被政府使用，但不一定会受到决策环节的约束，例如执法筛查，事实上强化了行政机关的能力，但不受法律约束。）

上述例子或许仍低估了机器学习的重要性。后者是一套“强大且高度通用的能力”，“原则上……可应用于任何复杂系统的管理，从汽车的转向与导航到公共政策的制定。”[10] 因此，机器学习能够生成具有行动指导意义的预测：谁应当被羁押，[11] 谁应当被驱逐出境，[12] 谁应当接受审计，[13] 谁应当被解除公职，[14] 谁应当被认定为需要国家援助，[15] 甚至谁应当被处决。[16] （算法不一定直接做出最终决策，但会强有力地影响最终决定，现有的法律问责制度可能无法穿透这种复杂的决策流程。）

在这些应用中，机器学习既有可能显著改善人类决策固有的缺陷，也有可能产生新的社会成本，并加剧有害的社会分层形式。

本文记录了国家行为中这一正在进行的技术转型。随后，我将分析在国家日益依赖机器学习的背景下，正当程序、平等与隐私等重要个人权利应如何被重新理解并加以落实。我的首要目标是描述性的。我着重关注机器学习国家中那些最尖锐地触及权利关切的具体应用场景。

尽管新型计算工具技术可在政策制定、立法及行政过程的诸多环节中使用，但我认为，当算法直接导致某项国家福利或惩罚被授予（或拒绝）某一特定个体时，最严峻的规范性问题便会出现。[17] 这当然并非唯一会引发担忧的机器学习应用场景。当机器学习工具被用于分配调查资源时，也会产生规范性关切，尤其是当成为调查对象本身就会带来即时成本之时。

通过梳理州和地方政府当前及未来可能采用机器学习的实例，我指出这些部署如何牵涉正当程序、平等与隐私方面的关切。我并不声称这些担忧完全是全新的。在某些情况下，宪法关切与人类行为所引发的问题相类似；而在其他情况下，当涉及机器时，则会产生全新的忧虑。

这一描述性工作得益于一个事实：已有越来越多分散的原告开始在联邦和州法院挑战算法工具。[18] 相关案件已出现在威斯康星州、[19] 加利福尼亚州、[20] 俄亥俄州[21] 和纽约州[22] 的保释与量刑领域。诉讼常常围绕某一特定算法能否在不违反商业秘密法的前提下予以披露而展开。[23]（美国已有司法案例）

法律问题并不仅限于刑事司法领域。在休斯顿，一个教师工会曾就一项用于评估工作表现并决定解雇的算法工具提起诉讼，理由是其违反了正当程序。[24] 在阿肯色州，该州残障福利领取者起诉阿肯色州人类服务部，指控其“非法转用计算机算法”的做法违反了该州的行政程序法。[25]

然而，这些案件均未正面应对机器学习国家所提出的全新宪法挑战。恰恰相反，它们对这些问题的回避，暗示我们亟需更系统地思考：相关宪法规范应如何调整，现有规制与诉讼结构又该如何改造，方能有效实现当今时代的宪法合规。

在建立描述性基础之后，我将展开两条规范性分析路径。第一条探讨当国家从人类行动转向机器行动时，正当程序、隐私与平等规范应如何进行有益的再校准。第二条，我将提出一个关于如何构建权利执行机制的一般性框架，以充分回应机器学习国家的独特属性。在此我简要勾勒这两条分析主线的核心要点。

关于第一个宪法实体问题，我聚焦于正当程序、平等与信息隐私关切，因为它们似乎是机器学习国家中最直接相关的权利。尽管最高法院已就正当程序与隐私发展出详尽的教义体系，但信息隐私的宪法法理却相当薄弱。

即便考虑到三者在教义发展程度上的差异，现有教义表述与机器学习的技术现实

之间仍存在明显鸿沟。当焦点从人类行动转向机器行动时，现行教义表述未必能准确反映正当程序、平等或隐私权利背后的价值。（也许这些教义形式在更普通的非机器制度环境中也并不契合，但这并非本文所关注的问题。）

即使机器学习工具并未完全取代人类判断，即使过去的决策也曾部分依赖清单或简单算法等结构化工具，我仍认为，机器学习工具以不同于人类行动的方式提出了宪法关切。然而，宪法权利历来是以人类行为为参照进行校准的。[26]

我在此的 modest aim（谦逊目标）是初步提出一些在新技术格局下调整或延伸教义的可能路径。需要强调的是，这些只是建议，而非确定无疑的处方。技术与社会格局正在迅速变化，妄言确定性实属愚蠢。我的目的仅在于开启一场对话，而非提供最终答案。

技术变革以微妙而不同的方式对正当程序、平等与隐私利益的界定施加压力。例如，在法院历史上处理的最典型案件中，正当程序通过给予受规制主体在个别裁决者面前听证的机会，或向新裁决者提出上诉的权利得以实现。

然而，如果我们关注的是最小化假阳性与假阴性的总体数量，那么对机器决策提起人类上诉往往是适得其反的。相反，正当程序可能要求修改分类器本身，以降低错误风险。

一个关于从人类判断转向机器推断所引发的宪法平等问题的例子，是刑事司法系统中累犯风险的计算。在此情境下，应如何定义并监管歧视？一方面，计算预测工具的广泛使用很可能减少法官、治安官等裁决者因显性或隐性偏见而影响决策的机会。

另一方面，这些工具也可能以某种方式嵌入关于种族和族裔群体的假设，从而复制不良的居住、经济与社会分层模式。这种情况可能在没有任何故意歧视的情况下发生，并涉及多种截然不同的机制。

如果说对人类行为者的平等规制可有效聚焦于“偏见”与“歧视意图”等概念，那么对于计算预测工具而言，或许更有用的是从其可预见的差别性影响（disparate effects）角度加以考量。

最后，考虑隐私问题。第四修正案下的宪法规则主要规范国家如何收集公民及其他受规制主体的数据，而对于这些信息如何被使用则几乎未置一词。[27]

一种允许国家利用公开数据——如监控录像、公共记录以及不受第四修正案保护的商业记录——来洞察个人行为的技术，意味着国家可以规避受第四修正案规制的 surveillance（监控），却仍能相对轻松地获取相同信息。

因此，由于技术变革，现有的第四修正案将越来越难以庇护宪法隐私利益。事实

上，来自国家的隐私风险可能很快会通过完全意想不到的渠道出现，例如，通过国家为实施机器学习工具而创建的数据库遭遇数据盗窃。[28]

除了上述具体关切，还有第二个、更为抽象的理由，促使我们密切关注机器学习国家中宪法权利的实施。目前，关于计算工具的知识与理解尚未广泛普及。公众尤其缺乏对这些工具及其局限性的清晰或准确理解。

机器学习甚至在法律从业者尚未充分掌握相关技术知识或实践认知之前，就已在国家机构中扎根。有理由预测，机器学习的新应用将赋予国家新的能力，但对法律体系参与者和公众而言，这些能力也将格外难以理解。

事实上，有理由担忧：国家权力的增强，可能与受规制主体理解或挑战该权力行使的能力下降呈正相关。[29] 当然，这种不对称效应或许会被善意的计算机科学家努力向公众和法律界普及机器学习知识所缓解。但我怀疑此类努力是否足够。

因此，国家采用预测与推断工具，很可能会在政府活动范围不断扩大的同时，进一步增加公民监督和回应这些活动的难度。

本文的第二项主要贡献，是对最有利于实现宪法价值的制度安排进行分析。目前，正当程序、隐私与平等的宪法规范，主要通过一种普通法式的、离散的、渐进的、事后诉讼过程得以发展和落实。

该过程在很大程度上依赖于通常与普通法相关的“侵权责任”（liability in tort）模型。[30] 在此前的研究中，我曾批评过在常规非机器治理中宪法权利所采取的离散化、个体化的执行形式。我认为，这些形式往往未能有效约束国家，且体现了颇具争议甚至倒退的道德直觉。[31]

我也曾主张，应从涉及集体利益的系统性动态角度来理解宪法损害。[32]

与上述论点一致，我在本文中主张：机器学习工具所引发的宪法关切，如同许多其他公共政策问题一样，最好通过事前规制（ex ante regulation）与集体诉讼（aggregate litigation）（即旨在维护特定个体利益的诉讼）相结合的方式加以应对。

在机器学习国家之外，这种聚合性模型 largely failed（在很大程度上已告失败）。这一失败在很大程度上源于法官对某些宪法权利（以及可能也对某些群体，如刑事被告和囚犯）的敌意。

但计算工具的新颖性提供了一个改进的机会。因此，我在此强调：机器学习国家特别适合采用事前规制与事后集体审计（collective auditing）相结合的模式（尽管这并不意味着非算法政策不能从同样方法中受益）。

具体而言，我探讨了各类事前规制策略的应用，例如技术强制要求和多种形式的

透明度机制。此类干预的一个目标，是促进事后探究：机器学习工具在“真实世界”（in the wild）中的表现如何（这可能与其在“实验室”（in the lab）中的表现大相径庭）。

此外，关于通过事后诉讼对工具进行审计，我强调了整体性、前瞻性、系统性救济形式（wholesale, prospective, and system-wide forms of relief）的效用。

再次强调，下文所述绝不意味着类似的规制与集体诉讼组合不适用于其他情境。恰恰相反。或许正是机器学习语境中的“新奇冲击”（shock of the new），将促使我们更普遍地重新思考：应如何通过规制来实现宪法权利。

本文的论证结构如下：第一部分回顾国家如何日益倚重机器学习工具作为人类决策的辅助或替代；第二部分探讨正当程序、隐私与平等价值应如何重新校准；第三部分则考察如何结合事前规制与事后集体诉讼，以确保机器学习工具始终符合宪法规范。

I. 在政府治理中转向使用机器学习的趋势

在过去十年中，机器学习计算科学的进步催生了预测与推断的新功能。[32] 国家利用这些新工具，或为实现传统的政策目标，或为追求全新的目的。无论其对宪法价值构成何种后续风险，国家几乎不可能放弃这些新技术。

除了效率提升之外，美国还面临来自国内利益集团（如大型科技公司）以及地缘战略竞争对手的强烈压力，亟需加速机器学习的发展与普及。[33] 因此，分析机器学习国家中的宪政主义，原因之一就在于：在国家职能日益扩大的背景下，后者被广泛采用具有政治上的必然性。

为此，本部分将描述所涉技术的核心特征、州及地方政府近期及即将开展的应用实例，以及由此引发的部分诉讼挑战。

A. 预测与推断的新工具

一般而言，机器学习算法是一种计算工具，旨在解决“通过某种训练经验，在执行某项任务时提升某种性能指标的学习问题”。[34] 在操作层面，机器学习可被简要描述如下：“你给机器提供数据、一个目标，并在其方向正确时给予反馈——然后让它自行找出实现目标的最佳方式。”[35]

以常见的监督学习（supervised learning）[36] 为例，其首先需要向算法提供一组带有标签的训练数据[37]，然后指令其推导（或“学习”）出一条规则，用以区分

训练样本中的两个子集。[38] 例如，训练数据可能包含一组图像，分别标注为“狗”、“猫”和“鼠”。算法随后可能被要求学习一条规则，将狗的图像与猫或鼠的图像区分开来。

监督学习可以是二元分类，也可以是多类别分类（如本例所示）。[39] 它也可用于估计连续变量，而非分类变量。算法从一个随机设定的决策规则开始，最初在预测正确子集方面的表现不会优于随机猜测。但通过不断扰动该规则并评估调整是否带来更准确或更不准确的结果，算法便能“学习”到一条有效规则，准确揭示数据特征如何映射到那些子集上。[40]

然而，这一分类规则并非人类设计的直接产物。

尽管上述解释看似简单，但机器学习工具在实际中可能极为复杂，以至于任何试图对其进行通俗解释或逆向工程的努力都注定失败。诚然，学界确实存在一场真实争论：即机器学习工具在本质上是否不同于早前广泛使用的统计模型——那些模型在计算能力尚不足以处理大数据的时代就已存在。[41]

无论这场争论如何解决，至少某些机器学习应用在量级上与早期统计技术的差异如此之大，以至于在效果上几乎可视为质的差异。

为理解这种潜在复杂性，可考虑深度学习网络（deep-learning networks）的例子。所谓“深度”，是指其依赖多层节点，输入数据经由这些节点逐层传递与处理。[42] 深度学习的重要形式包括循环神经网络（RNN），用于文本识别与翻译工具；以及卷积神经网络（CNN），是机器视觉的核心。[43]

RNN 和 CNN 均处理海量训练数据（例如数百万张图像或大量文本），每份数据包含成千上万甚至数百万个特征。它们利用网络化结构处理数据，而单个组成部分无法独立完成此类任务。早期具有影响力的深度学习工具之一，由杰弗里·辛顿（Geoffrey Hinton）及其同事设计，处理的数据包含约六千万个参数。[44]

深度网络能够执行一些简单工具无法完成的推断任务。如今，ChronoNet CNN 可通过分析照片图像估算其拍摄日期，[45] 并可通过检查脑电图（EEG）图像预测癫痫及其他脑部疾病的发病风险。[46]

任何机器学习工具的设计都涉及一系列判断，而这些判断并非由计算理论或算法设计的逻辑形式机械决定。尤为重要的是，设计者首先必须决定使用哪些训练数据。[47] 不同的训练数据选择将产生不同的预测模型。[48] （机器学习算法的特征、与传统算法的区别）

在国家行为的语境中，可用数据往往是历史国家实践的产物，例如公共福利管理，或对特定地理区域或种族/族裔聚居区的 policing（执法/监控）。如果这些历史

实践本身存在缺陷或偏见，那么由此产生的数据也可能因内嵌偏见、盲点或无根据的假设而变得不足或具有误导性。此类数据缺口或其他缺陷，随即向设计者提出进一步问题：是否（以及如何）采取纠正措施？[49]

一旦确定了训练数据集，设计者还必须决定在学习新规则时使用数据的哪些属性，即“特征”（features）。[50] 例如，性别、种族或其他受保护特征是否应被纳入？那么，那些可能与受保护特征高度且可预测地相关的变量呢——比如居住地的邮政编码（ZIP code）？（数据类型选取中就会涉及歧视、隐私等问题）如果某一非法分类标准或其紧密代理变量（proxy）对于实现合理的算法性能（无论该性能如何定义）是必要的，又该如何处理？（反歧视、隐私等法律约束又可能与算法决策的精准度要求相冲突。）

同时，设计者还需确定一个“结果变量”（outcome variable）。[51] 算法将优化一个由结果变量与模型参数共同构成的函数（即“损失函数”或 cost function），以此生成预测。[52]可能存在多个候选结果变量，但没有一个能精确对应政策真正关心的底层问题。于是，设计者不得不在不可靠的代理变量之间做出选择。[53] 同样，设计者必须决定哪种算法方法（例如朴素贝叶斯、随机森林、神经网络等）最适合其问题——这一选择要求她判断：是使用相对简单的工具，还是选用更复杂的深度学习工具。[54] 这种方法论选择绝非易事。[55] 业内人士形容该领域“各派系间常年处于部落式战争状态”。[56] 在这场争论中，日益复杂的工具设计的价值尤其备受质疑。一些计算机科学家警告称，新型预测工具的复杂性与精巧程度虽不断提升，但其性能增益尚不足以“在现实世界问题中转化为真正的实践优势”。[57]

此外，这仍非设计者所需作出判断的全部。设计机器学习工具的另一重大挑战是“过拟合”（overfitting）问题。[58] 这实质上发生在工具对训练数据拟合得过于完美，却未考虑到后者仅是从现实世界中抽取的一个含噪样本。解决过拟合问题，要求设计者在多大程度上限制模型从训练数据中“学习”的自由度作出判断。[59]

此外，计算工具所“学习”的只是“特定场景下的具体偶然性”。[60] 它并不掌握底层概念。这种浅层“理解”的后果是：当面对训练数据之外的示例时，工具可能变得脆弱。有风险表明，当工具“遭遇与其训练场景仅有细微差异的情境时，其成功预测率会迅速下降”——研究表明，“深度强化学习的解决方案往往极其肤浅”。[61] 在 Beta 测试之后，还可能出现“隐藏的反馈循环”（hidden feedback loops）。[62]对抗性策略（例如策略性地部署其他机器学习工具）也可能导致误分类。[63] 此类脆弱性可能带来非同小可、甚至“灾难性”（catastrophic）的后果。鉴于所有这些原因，我们不能想当然地认为：当机器学习工具应用于与训练数据

分布不同的新数据时，其行为仍可预测。

B. 机器学习国（的时代）

自十八世纪以来，国家建设的一个核心组成部分，便是不断深化信息收集能力，并削弱个人试图屏蔽国家凝视的私人努力。[65] 国家也一直寻求以“可读形式”（legible forms）记录关于公民个体的数据，以便于“阅读、处理与传递”。[66] 机器学习通过引入新手段，进一步推进了这些认知工程（epistemic projects）——它使公共机构能够利用因其他原因已掌握的数据。在私人领域，机器学习工具被用于排序（如谷歌和 Netflix 的算法）和分类（如信用评分工具和垃圾邮件过滤器）。[67] 国家可采用相同的排序与分类技术，推断受规制对象的过往行为，或预测其未来行动。这些推断随后可用于推进广泛的政策目标：改善刑事司法；优化教育政策（尤其是教师招聘与留任决策）；定向开展监管检查（如餐厅卫生检查）；识别有犯罪行为或卷入风险的青少年；以及预测个人财务结果（如违约可能性）。[68] 与此同时，也没有理由认为预测仅会被用于仁慈或明智的目的。海外已有预测工具被用于压制政治反对派。[69] 换言之，作为一项政策工具，机器学习本身并无内在的“善”或“恶”；其规范价值取决于其部署方式及所施加的附带成本。

本小节梳理联邦、州及地方政府在民事与刑事领域当前及未来可能采用机器学习的情况。在民事领域，预测工具被用于分配执法资源、作出雇佣决定以及分配福利。在刑事领域，算法则被用于实施强制措施——无论是以警务资源还是监禁的形式——既可在刑事审判前使用，也可在量刑后适用。

我必须强调，目前机器学习的采用仍极不均衡。许多司法辖区目前使用的预测工具，并非基于前文 I.A 小节所述方法开发。例如，巴尔的摩市在保释决定中使用的是由该市审前释放服务处（Pretrial Release Services）制定的一份表格，其中包含七个问题和十二项减轻或加重因素的清单。[70] （现实中不少算法还是代码驱动的，不完全是机器学习型的。）但这种情况似乎难以持久。例如，一项近期利用纽约保释数据的研究宣称，深度学习可能在审前实践中带来巨大的效率提升。[71] 鉴于成本节约的诱惑（无疑还有希望销售预测工具的企业及其顾问学者的游说），各州很可能会比预期更早地采用机器学习工具，取代临床评估或简单的人类判断。

因此，下文所述应被理解为例示（exemplifying）而非穷尽（exhausting）未来短期内可能出现的各类应用场景。

1、机器学习与监管型国家（算法在执法筛查）

利用机器学习来指导执法资源（例如餐厅检查员、税务稽查和欺诈检测）的做法正变得越来越普遍。[72] 这些由机器引导的裁量行为中，有些引发了重要的伦理和宪法问题。例如，关于如何分配执法资源的决策可能引发对种族或族裔偏见的担忧。[73] [1]当预测工具被直接用于向个人施加强制措施或分配福利时，显然可能引发正当程序方面的忧虑。（两类场景、两种担忧，传统公法上的担忧。对应国家的两种职能：执法监管与福利发放/资格审查）此外，任何数据聚合都可能招致隐私方面的异议。（还会产生个人信息方面的新忧虑）作为例证，我在此指出一种用于分配调查资源的机器学习工具，其应用背景充满了规范性风险。

论证逻辑：介绍一个具体应用——该应用存在风险——现有法律无法约束这些风险

该预测工具于 2016 年 8 月在宾夕法尼亚州阿勒格尼县推出。[74] 阿勒格尼家庭筛查工具（AFST）从多个州级机构协作创建的数据集中提取了 71 项特征，用以预测拨打州政府热线电话中哪些可能存在虐待或忽视儿童的情况。[75] [2] AFST 生成的反映虐待风险的评分会显示给接听并筛选此类来电的案件工作人员，用以辅助其决定是否展开调查。[76] 而一旦展开调查，就有可能最终导致将儿童从家中带走。为避免工作人员过度依赖评分而忽视更细致的信息，系统特意控制了评分披露的时机。[77] 然而，案件工作人员仍可能假定 AFST 评分比他们自己的观察更为准确。[78] （这里有人机交互关系：1、算法给出决策的时机，先让人类自行判断；2、地位是辅助人类决策。）佛罗里达州于 2012 年实施了一种类似的预测工具，[79] 并且已有多个州正在研究其经验，以决定是否效仿。[80]

评论人士对 AFST 系统提出了三项规范性关切。第一，有证据表明，在阿勒格尼县，基于 AFST 评分所作的决策存在种族差异。例如，黑人家庭似乎因一些看似无害的事件（如错过医生预约）而遭受“不成比例的转介”。[81] [1] AFST 的设计者意识到，无论是案件工作人员的敌意，还是非种族数据（如居住地邮政编码）与种族之间的相关性，都可能导致对风险程度相同的黑人儿童与白人儿童采取差别对待。[82] （反歧视的要求）

第二，一些观察者担忧，父母会因“其全部历史……被简化为一个单一数字”而产生“去人性化”的感受。[83]

第三，AFST 系统通过整合各类分散信息，依赖海量的政府数据。此类数据

---

[1] Kristen M. Altenburger & Daniel E. Ho, *When Algorithms Import Private Bias into Public Enforcement: The Promise and Limitations of Statistical Debiasing Solutions*, 175 J. INSTITUTIONAL & THEORETICAL ECON. 98, 99 (2019) (发现对于种族类餐厅会过度报告).

[2] Virginia Eubanks, *Automating Inequality: How High-Tech Tools Profile, Police, And Punish The Poor* 132–42 (2018) (描述了 AFST 的部署情况）。

聚合可能揭示大量私人事实与行为，从而很可能带来新的数据泄露风险。[84] 简言之，平等、正当程序和隐私在这套阿勒格尼县系统中都可能受到威胁。（个人信息风险）

尽管存在这些关切，但类似 AFST 评分形式的机器学习应用在宪法规范下所受的约束却相对薄弱。联邦行政法对放弃执法[3]或以其他方式管理监管“日常”实施的决策几乎不设限制。[4] 事实上，“近乎不受约束的裁量权”正是“许多行政决策的标志”。[5] 算法技术的部署可能使此类评估更加困难，具体取决于机器生成的书面记录相较于人类决策者所产生的记录性质。通常（即便并非必然[88]），那些被启动执法程序的对象也缺乏足够的证据基础，难以就自己因正当程序或平等理由而被不公平地单独挑出提出申诉。简言之，针对 AFST 系统提出的涉及平等或正当程序的诉讼面临重重障碍。（选择对谁执法的行政裁量权几乎不受到约束。）p.1894

2、机器学习与分配型国家（算法直接决定福利）

机器学习工具可用于分配或撤销个体化福利，例如就业机会或财政援助。[89] 21 世纪初，各州开始在更大范围的福利改革运动背景下，推动公共福利系统的自动化，旨在减少福利领取者人数。[90] 例如，密歇根州引入了一种算法工具，作为该州信息技术整体改革的一部分，用于检测失业救济申请中的欺诈行为。[91] 此后，各州越来越多地依赖算法工具来分配公共福利和政府就业岗位。[92] 在这些领域，以算法取代人类决策所引发的法律挑战，通常聚焦于机器决策在程序上的充分性。[6]尤其是，原告强调错误剥夺的风险。尽管对平等或隐私问题的关注较少，但这些问题也可能潜伏于背景之中。

以下两个例子说明了此类工具的使用方式及其当前在法院面临的挑战。第一个案例发生于 2016 年，当时阿肯色州采用了一家名为 InterRAI 的公司开发的算法来计算残疾福利。[94] 该算法并非基于机器学习方法开发。相反，InterRAI 是一种临床评估工具，[95] 它依靠约 60 项“描述、症状和疾病”来确定居家护理服务的配给量。[96] （我在此提及它，是因为它有助于说明未来更复杂的工具可能面临的挑战类型。）根据阿肯色州法律援助组织提起的诉讼——该诉讼以州行政法为依据质疑 InterRAI 算法——该工具对受益人主治医师的意见“未予任何权

---

[3] Heckler v. Chaney, 470 U.S. 821, 832–33 (1985).
[4] Norton v. S. Utah Wilderness All., 542 U.S. 55, 64, 66–67 (2004).
[5] Mariano-Florentino Cu´ ellar, *Auditing Executive Discretion*, 82 NOTRE DAME L. REV. 227, 229–30 & n.2 (2006); accord Rachel E. Barkow, *Foreword: Overseeing Agency Enforcement*, 84 GEO. WASH. L. REV. 1129, 1130 (2016) (“行政机关执法政策的大部分方面都一般性地规避了司法审查”).
[6] See, e.g., Hous. Fed’n of Teachers, Local 2415 v. Hous. Indep. Sch. Dist., 251 F. Supp. 3d 1168, 1176–77 (S.D. Tex. 2017) (主张被用于评估并且可能解雇教师的机器学习工具违反了程序性正当程序的要求).

重”。[97] （考量因素在设计上存在缺陷） 阿肯色州最高法院裁定禁止使用该工具，理由是其实施违反了该州的行政程序法，未经过充分的公示与评议程序。[98] [7]（法院裁判认为其属于立法性规则，需要经过公示与评议程序）p.1895

诉讼中提出的一个观点是，InterRAI 工具在面对特定病例中症状表现的细微或异常变化时可能显得脆弱（brittle）。[99] 例如，对同一人的“足部问题”输入不同的评估，即使该人状况完全相同，也会产生“截然不同的评分”。[100] 类似的担忧也出现在医疗补助（Medicaid）资格的算法判定中。[101] 在机器学习语境下，这种脆弱性引发了对从训练数据中学得的分类器外部有效性的质疑。[102]（本案中，算法的脆弱性是被认为存在缺陷的理由之一，那么机器学习算法在这点上更可能被攻击。）

第二个领域涉及利用大量政府数据驱动算法对特定个人作出判断，即公立学校教师的招聘与留任。近期的诉讼再次揭示了这一做法。

2010 年，休斯顿独立学区转向“数据驱动”的教师评估。[103] 它采用了“教育增值评估系统”（EVAAS）。[104] EVAAS 通过比较教师所教学生平均考试成绩的提升幅度与全州平均水平，计算出一个“教师增值指数”。[105] 然而，一个教师工会说服了一名地区法院法官：当一名教师因 EVAAS 分数过低而被解雇时，其正当程序权利受到了侵犯。[106] 工会辩称，即使教师能够接触到算法的底层代码，也无法复现自己的评分。[107] 而该评分“可能因多种原因被错误计算”。[108] 学区最终与工会达成和解，支付了欠薪并停止使用 EVAAS。[109]

不过，休斯顿并非唯一在招聘中寻求算法解决方案的地区。2015 年，亚特兰大公立学校聘请了 HireVue 公司协助教师招聘。[110] HireVue 提供深度学习工具，通过在线视频面试中的面部特征和面试表现来推断求职者的工作表现。[111] HireVue 的材料并未披露如何评估申请人，但其描述与使用情感识别软件的做法一致。[112] 目前尚不清楚亚特兰大学区（或其他公共机构）是仅使用 HireVue 的视频捕捉功能，还是也使用了其整套预测工具。[113]

其他对算法分配政府福利的挑战者也诉诸正当程序论点。例如，在印第安纳州，2012 年一项福利申请被自动拒绝的决定，因系统未能向受益人提供关于重要福利被剥夺的充分信息，而成功以正当程序理由被推翻。[114] 在密歇根州，用于标记欺诈性失业救济申请的自动系统也遭到挑战，理由是该系统“未向申请人提供对其指控的通知，而这种通知缺失以及其他系统性问题剥夺了申请人获得公平听证的权利”。[115] 相比之下，我尚未找到基于平等或隐私关切对算法分配系统提

[7] Ark. Dep’t of Human Servs. v. Ledgerwood, 530 S.W.3d 336, 344–45 (Ark. 2017).

出挑战的案例。这可能是因为正当程序主张更容易提出：它们只需了解决策表面上是如何作出的，而无需了解不同群体如何受到分类决策的影响，或后台如何处理数据。另一种可能是，这种空白源于程序性正当程序在挑战福利分配与撤销的历史渊源。[116] 这意味着人们更容易设想正当程序挑战，而非平等或隐私挑战。但这并不必然意味着正当程序问题更为普遍。（除了程序性问题，算法决策还存在实体性的不公正、隐私问题，但尚未被提出挑战。）

然而，福利分配中的种族或隐私影响很可能也是真实存在的。[117] 为理解这一点，可参考 Khiara Bridges 关于信息隐私与贫困母亲福利制度交叉的研究。Bridges 的分析虽不直接涉及计算决策工具本身，却揭示了在使用算法分配公共福利时可能出现的重要但尚未被充分讨论的规范性问题。[118] 她强调，向贫困母亲提供的国家援助往往以披露大量有关其行为和社会环境的个人信息为前提。[119] Bridges 认为，这种隐私剥夺无法用对母亲或儿童健康福祉的关切来解释；她推断，若非基于对该群体的某种基本预设，“甚至不会有人尝试这样做”。[120] Bridges 的论点呼应了更早的社会学与政治学研究传统，这些研究强调种族刻板印象如何塑造了福利政策。[121] 但她提出的规范性关切在算法语境下可能变得愈发相关。例如，用于算法福利分配的信息收集主体是公共机构，而相较于商业银行等私营实体，它们可能更容易遭遇数据泄露。[122] 这意味着，对这些工具日益增长的依赖很可能会将更多数据泄露风险的负担转移给贫困人口。[123] 因此，机器学习的采用不仅会对隐私权造成负担，还会产生具有累退性和种族差异的经济影响。

3、机器学习与惩罚型国家：以人脸识别为例

机器学习日益应用的第三个领域，是通过警务、监禁乃至（在极端情况下）武力来提供公共安全。目前已有大量文献探讨机器学习在警务、[124] 保释与提审程序[125] 以及量刑[126] 中的部署。这些文献描绘了机器学习工具及其他算法如何被用于预测未来的暴力行为或犯罪倾向。基于地点的预测（例如 PredPol 等警务应用程序生成的预测）被用于分配调查资源。[127] 其他预测则聚焦于特定个体。例如，COMPAS 算法在许多司法管辖区被用于协助保释决定，它为被告生成 1 到 10 的风险评分，供负责设定或拒绝保释的治安法官参考。[128]

与其重复已被广泛讨论的预测性警务和保释算法细节，我在此聚焦于执法部门部署机器学习的一个新前沿：利用人脸识别技术从公共监控和随身摄像头录像中识别个人身份。[129] 人脸识别技术提供了一个有用的案例研究，展示了当国家利用机器学习工具从原本无意义的数据中进行推断时，程序公正、平等与隐私等规范如何以复杂且不可预测的方式相互作用。

目前，大约一半的美国成年人已被纳入一个或多个美国执法机构的人脸识别数据

库中。[130] 这些数据库可用于匹配特定案件中的视觉证据并实施逮捕。[131] 更具争议的是，它们还可用于识别反对政府政策的抗议活动参与者。[132] 其采用速度尚不确定。2018 年 5 月，美国最大的随身摄像头制造商之一 Axon 公司为其警员随身摄像头实时识别人脸的技术申请了专利。[133] 然而，2019 年 6 月，该公司宣布因可靠性问题暂不安装该工具。[134] 目前，个性化的人脸识别结果可能尚无法及时以适当方式传达给警员，使其据此采取行动。但这种平衡不太可能持久。

人脸识别引发了相互关联的隐私、程序公正和平等关切。以 2015 年一项广受关注的研究为例，该研究利用八项面部特征来识别特定个体。[135] 研究在美军提供的 3,982 张人脸图像样本中未发现重复，并据此认为人脸识别的准确性可与 DNA 比对相媲美。[136] 然而，2019 年的一篇论文指出，该结论建立在对这些特征某些参数值统计分布的未经检验的假设之上。[137] 它质疑 2015 年研究的外部有效性。例如，该研究假设人脸是静态且不随时间变化的。但“衰老、疾病、疲劳、表情变化，或摄像头角度造成的面部变形”都会改变这八项面部特征的数值。[138] 即便人脸识别在理想条件下准确，警察却是在非理想条件下部署它的。事实上，他们甚至以颇具创意的方式使用它。例如，在纽约市，当警员只掌握药房盗窃案中一张部分人脸的监控截图时，他们竟使用演员伍迪·哈里森（Woody Harrelson）的高清视频图像进行匹配，理由是监控中的部分图像看起来像哈里森。[139]

实验室环境下的人脸识别系统的错误率在种族、性别和年龄维度上也分布不均。这是由于训练数据主要使用了较年长、男性化和白人为主的样本人脸。例如，2018 年一项对两种商用人脸识别工具（IJB-A 和 Adience）的研究发现，两者均以白人为主体进行训练，对黑人女性的错误率比对白人男性的高出 34.7%。[140] 在隐私方面，联邦或州法律对警方从人脸图像中得出的推断几乎未加规制。也有证据表明，人脸图像可支持“跨类别”推断，例如健康状况。例如，它们可能通过孕妇产前发布的照片预测产后抑郁症。[141]

人脸识别还可能被严重滥用。2016 年，两名中国研究人员使用 1,856 张中国男性照片构建了一个预测工具，试图区分“罪犯”与“非罪犯”两类“流形”（manifolds）的人脸类型。[142] 该研究结果遭到广泛批评。例如，其训练数据样本过小，难以避免过拟合。[143] 此外，许多“非罪犯”人脸（但无一“罪犯”人脸）穿着白色衬衫，这很可能引入混淆变量。尽管如此，设想警方如今基于此类人脸识别工具生成“罪犯类型”名单并非天方夜谭——正如他们曾试图（但未成功）利用社交网络创建“战略性对象名单”以识别未来可能犯罪者一样。[144] 尽管由此产生的推断存在缺陷，但仍可能深刻影响警方实践。

目前极少有诉讼检验刑事司法领域算法决策所受的宪法约束。[145] 现有的判例

法主要聚焦于正当程序问题，略微触及平等关切，而基本上忽略了隐私价值。[146] 其原因之一在于，在刑事司法语境中，缺乏有效途径对机器学习工具提出法律挑战。例如，在警务方面，只要个人与警方接触的法律依据符合宪法要求，个体诉讼当事人就很难挑战使用机器学习工具分配警务资源的做法。[147] 此外，以集体诉讼形式对不同地理区域间警务资源分配提出的系统性挑战极为罕见。[148] 此类诉讼调查和诉讼成本高昂，且很可能因《美国宪法》第三条的诉讼资格（standing）问题以及是否适合按《联邦民事诉讼规则》第 23 条进行集体诉讼而失败。

一些案件出现在审前和量刑阶段的个体化风险评估中。例如，2016 年，威斯康星州最高法院驳回了一项针对 COMPAS 算法的正当程序挑战，理由是被告仅能以宽泛笼统的方式质疑该算法，而无法审查算法在具体案件中所依赖的个体化数据。[149] 法院认为，该算法仅依赖公开可用的数据，并指出被告本可以否认或解释用于生成其预测的任何信息。[150] 法院顺便提到，性别等特征属于用于被告量刑的大量输入因素之一。[151] 法院警告称，仅凭此类因素，“不得作为决定罪犯能否在社区中安全有效接受监督的决定性因素”，否则将违反正当程序。[152]（一些不当的数据选取也会违反正当程序。）

尽管针对人脸识别使用的诉讼尚未出现，但监管回应已开始启动。2019 年 5 月，旧金山监事会投票禁止警方采用或实施人脸识别技术。[153] 然而，包括纽约、拉斯维加斯、底特律、波士顿和奥兰多在内的众多城市已采纳该技术，且未显示出放弃的迹象。纽约市已颁布一项条例，设立专家委员会，负责监督并就算法技术的部署提出建议。[154] 但此类机构将如何运作，以及能否抗衡警察等强势利益集团，仍有待观察。

威斯康星州的判决，如同阿肯色州对残疾福利分配算法的挑战以及休斯顿对教师评估的挑战一样，几乎完全围绕程序性关切展开。然而，尽管已有大量争议性文献分析种族因素在 COMPAS 算法中的作用，[155] 至今尚无诉讼明确挑战这些影响。同样，学术界或司法界对为公共安全目的而创建大规模数据聚合所引发的隐私风险也鲜有论述。然而，即使警方拥有的资源可能多于（例如）公立医院，也没有理由认为他们能免于数据泄露的风险。

小结

机器学习工具正迅速扩散至民事和刑事监管的各个领域。目前，它们的监管仍是零散的。然而，它们持续引发一组共同的程序性正当程序、平等和隐私关切。法院和评论人士已初步察觉到这些关切。但迄今为止，法官们既未提供一个连贯的框架来说明这些关切如何交织，也未阐明如何识别它们，更不用说如何缓解了。

II 在机器学习国家中适用宪法价值

鉴于联邦和各州当局正迅速且持续地采用机器学习技术，宪法利益应如何重新调整，以适应机器学习国家所塑造的新格局？本部分聚焦于正当程序、平等与隐私这三项宪法规范——它们在预测性工具的设计与运行中反复受到牵涉。本文将分析在将这些规范适用于机器学习国家时所面临的困难。

A. 程序性正当程序

法院对机器学习工具提出的常见控诉是，其未能向受规制主体提供程序性正当程序。[15 6] 大量轶事证据表明，个体曾被算法错误分类，而此类错误本可通过人工介入迅速且轻易地纠正。例如，在一项颇具影响力的论述中，数据科学家凯西·奥尼尔（Cathy O'Neill）描述了一位福利申请人因自动化的"网络爬虫式数据收集"背景审查而失败。[15 7] 只有当"一位有责任心的人"费心核查该机器结果的质量时，错误才被发现并修正。[15 8] 其隐含之意是：机器容易出错，因此在任何算法驱动的程序中，由人类裁决者主持某种形式的听证会是必要的矫正机制。

然而，仅聚焦于孤立个案中的错误，作为正当程序分析的基础并不可靠。我主张，正当程序的违反发生在算法未能在整个受规制案件群体中达到可接受的准确度水平之时。（本文认为，违反正当程序的判断标准不是个案中是否有相关的程序，而是算法的准确率是否符合一定的水平。）因此，正当程序关切源于设计容差（design margins）的校准方式——这些方式使相关错误更可能发生，而非更少。宪法分析因而必须聚焦于那些在时间上远早于个体遭受算法分类那一刻的算法设计选择。（正当程序分析应该关注系统性问题，而非个案决策那一个时间节点。）对正当程序缺陷的救济不太可能采取额外人工复审的形式，而更可能体现为更优的算法设计。本着这一精神，我在此识别若干相关的设计维度。我还强调，并非总能同时消除假阴性（false negatives）与假阳性（false positives）；相反，必须作出取舍，决定容忍哪一类错误。在算法语境下——当我们可以事先精确设定错误的平衡与类型时——正当程序便必然包含关于不同类型错误相对代价的规范性判断。尽管这些判断在人类决策过程中已隐含存在，但在机器决策语境中，它们可以被分离出来并以更高精度加以处理。

1、程序性正当程序规范

在判例法上占主导地位的程序性正当程序模型，其焦点狭隘地具有"功利主

义”色彩，即关注“以最高效的方式达成最准确的结论”。[158][8] 在正当程序语境中，“准确性”被理解为决策程序的结果与某种经验性“真实情况”（ground truth）之间的相关性。[160][9] 而以尊严或参与内在价值为基础的替代性观念，尚未获得判例法的认可。[161][10]这种以工具性和准确性为核心的正当程序观，在著名的马修斯诉埃尔德里奇案（Mathews v. Eldridge）所确立的三要素检验标准中得以定型。[162]（在美国目前的判例中，正当程序的作用仍是工具属性的，目标是得出正确的结论，尊严、内在价值在判例中未得到认可。）

在该案中，最高法院将注意力引向：“私人利益”；“错误剥夺该利益的风险”以及“附加或替代性程序保障措施可能带来的价值”；以及“政府利益，包括所涉职能及附加或替代性程序要求所带来的财政与行政负担”。[163] 这些因素应从整体上审视裁决机制，而非拘泥于单一案件的具体细节。就此而言，正当程序挑战通常带有“面挑战”（facial challenge）的特征。

在适用中，马修斯检验依赖于一些困难——甚至可能是无法解决的——反事实问题：例如，政府在潜在替代制度安排之间的选择、私人个体在不同裁决安排下的行为，以及对这些安排进行边际调整所能带来的准确性收益。[164] 此外，该检验将非工具性考量完全排除在正当程序分析之外的做法也备受争议。但近五十年来，该检验标准始终有效。它在逻辑上可适用于新情境，包括机器学习被采用的场景。事实上，我将指出，相较于以往应用该标准的许多制度领域，整体性的马修斯检验在机器学习语境中或许更容易适用。

2、对机器学习的适用

关注算法决策程序质量的学术研究普遍解读马修斯案，认为其要求向受规制主体提供具体通知，并确保可获得个体化裁决——通常涉及人类裁决者。在早期分析中，丹妮尔·基茨·西特伦（Danielle Keats Citron）主张，合宪的充分通知应通过审计追踪（audit trail）实现，该追踪需记录案件中所有“作出的决策”以及系

---

[8] Martin H. Redish, Discovery Cost Allocation, Due Process, and the Constitution’s Role in Civil Litigation, 71 VAND. L. REV. 1847, 1863–64 (2018).

[9] 对于准确性，一种可选的概念聚焦在分类中对置信度的表达。参见 Robert J. MacCoun, The Epistemic Contract: Fostering an Appropriate Level of Public Trust in Experts, in MOTIVATING COOPERATION AND COMPLIANCE WITH AUTHORITY 191, 201–02 (Brian H. Bornstein & Alan J. Tomkins eds., 2015).尽管我不会长篇大论地主张 MacCoun 的观点，我稍后确实会解释不确定性和准确性在功能上重要的方式上互动。参见下文中脚注 185，讨论偏见/差异的权衡）。

[10] 基于人格尊严的逻辑在学术研究中被强有力地支持。例如，参见 Frank I. Michelman, Formal and Associational Aims in Procedural Due Process, in DUE PROCESS: NOMOS XVIII, at 126, 127–28 (J. Roland Pennock & John W. Chapman eds., 1977)（强调参与的价值作为正当程序的一项要素）；Jerry L. Mashaw, Administrative Due Process: The Quest for a Dignitary Theory, 61 B.U. L. REV. 885, 899 (1981)（进一步发展了正当程序的人格尊严理论）；Martin H. Redish & Lawrence C. Marshall, Adjudicatory Independence and the Values of Procedural Due Process, 95 YALE L.J. 455, 504 (1986)（主张/呼吁一个独立的裁决者来保护程序性正当程序）。

统在每个微小决策中“实际适用的规则”。[16 5] 在发展针对机器决策的听证权理念时，西特伦聚焦于人类裁决者接收算法建议的情境，并建议“各机构应要求听证官员详细说明其对自动化系统决策的依赖程度”。[16 6] 这一设想预设了在工具应用于特定案件后，仍可获得人工干预。

类似地，凯特·克劳福德（Kate Crawford）与杰森·舒尔茨（Jason Schultz）呼吁建立“程序性数据正当程序”，以规制大数据分析过程在使用个人数据（或元数据……）方面的公平性。[16 7] 与西特伦一样，他们似乎也是从细粒度、个体化的角度来构想正当程序的内涵。在他们看来，通知意味着披露算法所使用的“预测类型”和“数据的一般来源”。[16 8] 他们同样要求举行听证会，使受影响者能够审查“输入数据及所应用的算法逻辑”，并可向“中立的数据仲裁者”（推测为人类而非另一台机器）上诉，以解决有关分析与预测质量的争议。[16 9] 但他们是否认为正当程序还要求披露以下内容尚不明确：(1) 用于训练和生成学习规则的数据；或 (2) 用于对受规制主体作出预测或分类的个体数据。

在某种程度上类似的思路下，Cary Coglianese 与 David Lehr 通过建议向个体提供“关于他们的收集信息”以及“算法在测试数据集中对个体评估时的准确率信息”，来阐释通知义务。[17 0]

然而，这些提案聚焦于对个体案件进行人工上诉，可能因若干原因而未能抓住维护正当程序利益的最佳路径。首先，正如大卫·莱尔与保罗·奥姆（Paul Ohm）所解释的，“数据在选择和塑造过程中存在多种方式——例如在数据清洗或模型训练阶段——会损害预测质量”。[17 1] 预测偏离可接受准确模式的情况，可能源于训练数据的设计、结果变量的选择，或算法工具的选用。[17 2] 然而，个体化听证模式并不适合识别此类系统性问题。向所有受规制主体提供个体化听证权，固然有助于关注特定个体是否被正确分类，但诉讼当事人未必有动力去揭示系统性问题（而更倾向于突出自身案件中的错误）。因此，他们零散的挑战未必是判断算法决策过程中是否存在导致不准确的系统性缺陷的有效方式。[17 3][11] 事实上，裁决者面前某个具体个案出现错误，并不一定证明存在系统性设计问题，因为大多数算法都会产生某些错误。而一旦系统性缺陷被根除，个体化听证可能就成为一种不必要的昂贵负担。

其次，这些提案普遍假设：增加人工上诉可降低假阳性和假阴性的总体发生率。但我曾在别处论证，假定人类决策通常比机器分类更准确，或假定在机器决策后增加人工复审可降低错误率，是有问题的。[17 4] [12]我并非提出新观点。早在 1954

[11] 个体化的听证为审查系统性问题提供一种机制并非完全不可能。但这很难被认为是符合成本-收益的行为（对个体而言）。

[12] Aziz Z. Huq, *A Right to a Human Decision*, 105 VA. L. REV. (2020) ; accord Sharad Goel, Ravi Shroff, Jennifer Skeem & Christopher Slobogin, *The Accuracy, Equity, and Jurisprudence of Criminal Risk Assessment* 3

年，心理学家保罗·米尔（Paul Meehl）就比较了统计预测工具与专业人员的临床判断，得出结论：结构化决策（即使在当时）也优于单独的人类判断，甚至优于统计预测加人工复审的组合。[17 5] 近期研究也表明，向结构化（算法）决策增加人工监督，并不总能减少假阳性和假阴性的净数量，反而常产生不良甚至适得其反的效果。[17 6] [13]尽管不能完全排除成功整合事后人工监督与机器决策的系统的可能性，但当前聚焦于"听证官员"的提案更可能加剧而非解决这一正当程序关切。

3、以正当程序规范检验算法设计

本着克劳福德与舒尔茨的精神，**我主张将正当程序分析聚焦于系统性设计选择。**（这是在说算法的实体性问题，例如准确率、与决策目标的符合程度等，而不是讨论程序问题。）然而，他们并未充分说明设计如何可能损害正当程序，以及如何识别有问题的设计特征。为初步填补这一空白，我在此探讨五种可能通过算法设计产生的正当程序问题。这些问题均取决于机器学习工具的系统性属性。

【偏见、错误】第一，算法可能基于不完整、有偏见或存在缺陷的数据进行训练，而这些缺陷源于数据的创建、选择或清洗方式。[17 7] 由警察或儿童福利机构等执法部门生成的训练数据，可能受到官员或线人显性或隐性偏见的影响。[17 8] 其结果可能是某些群体（如少数族裔）被过度代表——并非因其不当行为率更高，而是因为他人更倾向于举报或调查他们。或者，由于政府未能在某些地区或针对某些人群执法，训练数据中可能出现"黑洞"。[17 9] 同样，此类缺陷的可预见后果是：预测结果偏离政府干预所意图针对的潜在构念（latent construct）（例如犯罪性、福利资格丧失风险或儿童虐待可能性）。正当程序至少要求算法设计者避免不必要地使用有缺陷的数据集，并在适当情况下主动采取措施缓解训练数据的缺陷。[18 0]

【对齐问题】第二，结果变量（outcome variable）可能与底层关注变量（即通常所称的"潜在构念"）错位。[18 1] 例如，结果变量可能依据原始数据中并不存在的特征来定义。刑事司法领域的风险评估算法旨在预测"危险性"——而这一分类在原始数据中并不存在。[18 2] 然而，这种人为构建的分类可能因多种原因与底层关注结果缺乏良好相关性。[18 3] 算法部署的制度环境也可能影响结果变量与潜在构

(Dec. 2018) (unpublished manuscript) (on file with author) (总结了证据，关于额外的程序会对精准度产生总体的负面效果)

[13] Thomas H. Cohen, Bailey Pendergast, & Scott W. VanBenschoten, *Examining Overrides of Risk Classifications for Offenders on Federal Supervision*, 80 FED. PROB. 12, 20–21 (2016); R. Karl Hanson & Kelly E. Morton-Bourgon, *The Characteristics of Persistent Sexual Offenders: A Meta-Analysis of Recidivism Studies*, 73 J. CONSULTING & CLINICAL PSYCHOL. 1154, 1154–56, 1159 (2005).

念之间的契合度。例如，人脸识别工具已被用于匹配警方画像师绘制的合成图像。[18 4] 但这些合成图像很可能是目标潜在构念（即真实嫌疑人的面部）的高度不完美版本。因此，允许基于画像师合成图像进行匹配的算法，会引入一个随机因素，导致可预见的高错误率，且该错误率在种族间分布不均。更一般而言，对潜在构念的拙劣选择本身就可能构成对正当程序的侵犯。

第三，算法设计者可能选择了一个与手头政策任务不相匹配的模型。这方面的一个重要选择涉及偏差/方差权衡（bias/variance trade-off）。模型选择会影响偏差（预测与真实情况的偏离程度）与方差（本质上，若在不同数据集上训练，预测结果的波动程度）之间必要且不可避免的权衡。有证据表明，较简单的模型往往表现优于更复杂的模型，因为其方差更低。[18 5] 根据政策背景的不同，可能基于模型如何管理这一权衡而偏好不同模型。当政策上一致性比精确性更重要时，偏差-方差权衡意味着可选择偏差较高的模型，并预期其会产生一定错误率。因此，若脱离模型选择与政策功能的关系，仅凭错误率就谴责或认可某一算法，可能会使正当程序分析误入歧途。

【算法的更新、评估】第四，算法可能基于适当的训练数据进行训练，最初也能提供有用的实地预测，但随后会遇到无法正确分类的案例。鉴于算法决策工具很可能在复杂且不断演变的社会环境中运行，通常有必要定期评估算法的表现，以确保其分类结果继续与潜在变量保持一致。科格利亚内塞与莱尔倡导披露算法在“测试数据集”中的准确率，[18 6] 可能正是出于对此类关切的考虑。但他们的提议可进一步扩展为考察算法在实地随时间推移的表现。

第五，存在一类情形：没有任何可用的结果变量能与底层关注变量形成足够强的相关性。因此，<u>算法的预测在逻辑上缺乏与合法政府利益的任何合理关联，从而在“非理性”意义上失效</u>。[18 7] [14] <u>正式立法与行政行为中的非理性问题，通常被界定为平等保护条款的违反，而非正当程序问题</u>。[18 8] [15] 但无论以何种方式表述，若某工具的结果变量与底层关注结果之间不存在合理相关性，则很可能构成宪法 violation。[18 9] （算法所使用的评估指标等与决策目的缺乏合理关联，因为实体问题而无效。）

---

[14] 我应将此处的观点与文献中一个类似观点加以区分。例如，西特伦（Citron）曾基于“合理性”关切提出，某些决策“明确或隐含地要求行使人类裁量权”（Citron，见前注 165，第 1302–1304 页）。而我在此提出的论点有所不同。西特伦的论证依托于一个广为人知的区分：规则（rules）的内容在受规制主体行为之前即已确定，而标准（standards）的内容则是在受规制主体行为之后才通过具体适用予以充实。
我认为，西特伦的这一观点在适用于机器学习时，在技术上并不准确。从技术角度看，并无理由认为算法工具不能对新样本进行分类，从而实现对“标准”的具体化（liquidate a standard）。例如，k 近邻算法（k-nearest neighbor, k-NN）正是通过对查询点附近最近的 k 个训练样本中最常出现的标签，来对新实例进行分类的。

[15] 参见《威洛布鲁克村诉奥莱克案》（Vill. of Willowbrook v. Olech），528 U.S. 562, 563–65（2000 年）（全体一致意见）（法院认为，原告主张被告的行为“非理性且完全任意”，已“足以根据传统的平等保护分析提出救济请求”，“无需考虑该村庄的主观动机”（引号内原文省略））；《罗默诉埃文斯案》（Romer v. Evans），517 U.S. 620, 631–36（1996 年）（裁定科罗拉多州宪法第二修正案“缺乏与合法政府利益之间的合理关联”）。

教师评估与刑事风险评估可能是典型案例。有大量证据表明，许多现有的教师绩效衡量指标——尤其是学生评价——受到各种不当的种族和性别偏见扭曲，[190] 或至少与学习成效的衡量指标无关。[191] 同时，标准化考试数据易受其他教师“应试技巧”操纵。因此，基于此类分数的教师效能衡量指标会出现年度间的任意波动。[192] 鉴于此，若算法基于学生评价或标准化考试成绩进行训练，则很可能因不准确或内嵌偏见而在正当程序或平等保护条款下自始无效。

再以 HireVue 工具为例，该工具可能已被亚特兰大公立学校用于教师招聘。[193] 据称，HireVue 使用了 Affectiva 公司开发的面部数据分析工具——“一家在情感识别领域领先的公司，业务涵盖市场研究与广告”。[194] 即使暂且搁置学界对情感识别理论前提的质疑，[195] 面部图像中检测到的情感如何能有意义地预测教师工作表现，也远非清晰。在招聘中使用此类情感识别技术，很可能引发严重的合理性问题——至少在公共部门，这具有宪法意涵。

至于保释或缓刑中的刑事风险评估最终是否可行，目前仍有争议。一组学者最近指出，即使在审前羁押人群中，暴力风险也极低，以至于从统计上几乎不可能区分出极少数未来会实施暴力行为的人。[196] 此外，这些学者认为，用于风险评级的训练数据不可避免地受到敌意影响。[197] 不过，也有其他学者反对这一结论，[198] 而暴力预测工具仍在广泛使用。

这份潜在设计缺陷清单——即算法设计可能出错的方式——再次申明，并非穷尽式列举。这些例子仅用以说明算法工具可能无法实现低错误率的若干途径。

4、马修斯案与机器学习

事先明确界定正当程序违反的条件，带来了一个耐人寻味的可能性：虽然马修斯检验在适用于基于机构的裁决系统时可能陷入不确定性，[199] 但在机器学习语境中，其适用却可能变得直接且可预测。离散的技术设计维度可被分离出来，并分析其对错误率的贡献。也就是说，在马修斯案近五十年后，技术或许终于使其判例焦点变得经验上可操作。但与此同时，这种可操作性也可能揭示马修斯检验本身固有的困难——而这些困难在以往的司法适用中一直被掩盖。

为使论述更具体，我们可从以下观察出发：算法工具会产生不同类型的错误。而且，通常在技术上无法同时最小化假阳性和假阴性。[200] [16] 因此，确定假阳性

[16] 关于探究算法设计中内在的权衡问题的论文，参见 Sam Corbett-Davies, Emma Pierson, Avi Feller, Sharad Goel, & Aziz Huq, Algorithmic Decision Making And The Cost Of Fairness, Proc. 23Rd Acm Sigkdd Int'L Conf. On Knowledge Discovery & Data Mining 797, 804–05 (2017); Jon Kleinberg, Sendhil Mullainathan, & Manish Raghavan, Inherent Trade-Offs In The Fair Determination Of Risk Scores, 8Th Innovations Theoretical Computer Sci. Conf., At 43:1, 43:4, 43:9, 43:17 (2016).

和假阴性的适当组合，将需要艰难的社会与规范性判断。这些判断在实践中常被回避或压制。在马修斯案的常规适用中，这些难题可被绕过；但在算法语境中，它们却难以回避。

例如，考虑一个二元分类系统（产生假阳性和假阴性），而非生成连续输出变量的分类器（其错误表现为程度差异）。前者在法律语境中更为熟悉。算法设计通过为假阳性和假阴性赋予不同权重，承认二者价值不同。[20 1] 如同在民事与刑事审判中通过调整证明标准为假阳性（或假阴性）隐含地赋予不同权重一样，计算工具也可调整观测到的假阳性和假阴性之间的平衡。但在刑事语境之外，正当程序应如何在不同组合的假阳性和假阴性之间界定？在特定情境下，社会对假阳性与假阴性所赋予的价值是一个判断问题。一般认为，错误定罪代价极高；而侵权诉讼中对原告的错误判决则代价较低。[20 2] 对算法正当程序的评估，需要对假阴性与假阳性相关代价的相对大小作出精确判断。[20 3] 然而，在保释决定、雇佣决策和福利分配等领域，对于不同类型错误的相对价值尚无共识。因此，判断何时满足正当程序，将迫使我们在特定政策领域就不同类型错误的价值展开前置性政策辩论。

在当前实践中，“非常常见”的做法是假定假阳性和假阴性带来相等的代价。[20 4] 但这似乎不是一个合理的普适解决方案。由于这一假设的失效，正当程序的适用将必然涉及对预测工具所规制的各种结果之社会成本的艰难判断。而这一过程本身就可能代价高昂且引发分歧。

小结

判断机器学习工具是否侵犯正当程序，需检验高质量训练数据、学习模型与结果变量之间的契合度，以及结果变量与潜在变量之间的匹配度。在某些方面，这比审查人类决策更困难；但在其他方面，它又更易于进行精确分析。

只要训练数据、学习模型、结果变量与潜在变量之间的契合足够紧密，机器学习工具就应在正当程序层面获得认可。我已用一般性且非技术性的语言描述了这些设计维度，包括训练数据选择与方法论选择。此外，在许多情况下，即使无法获取分类器的源代码，也可能对其设计选择作出判断。[20 5] [17] 正当程序设计维度的性质及其在事后审查中的可获性，对第三部分所分析的救济框架具有重要意涵。

B. 平等与反歧视规范

[17] Joshua A. Kroll et al., Accountable Algorithms, 165 U. PA. L. REV. 633, p.638 (2017) 讨论了源代码分析的局限性。

美国关于种族与性别平等的法律，体现在平等保护条款的宪法判例以及联邦反歧视成文法之中。[206] 本文聚焦于宪法法理，其核心在于意图（intent）与分类（classification）问题。我将探讨这些概念如何被适用于机器学习语境。然而，我认为，在实践中由算法系统引发的平等关切，更宜被理解为关乎其对有害社会分层（pernicious social stratification）所产生的影响。[207] 下文将以种族平等规范为主要讨论对象，尽管其中许多观点也可类推适用于其他领域。

1、平等保护规范

宪法上的平等法理以“意图”和“分类”作为核心分析范畴。[208] 自 1970 年代中期以来，最高法院将第十四修正案下的“基本平等保护原则”界定为：“一项被指称具有种族歧视性的法律，其‘恶意性质’最终必须追溯至一种种族歧视目的。”[209] 法院还裁定，凡政府“基于个人种族分类来分配负担或利益”的情形，均将触发严格审查（strict scrutiny）。[210] 要通过合宪性审查，此类分类的使用必须严格限缩（narrowly tailored）以服务于迫切的政府利益（compelling state interest）。[211] 这一“反分类”（anticlassification）法理的正当性基础在于：种族界线具有“分裂性”，且极少与合法政府目的相关。[212]

然而，“非法目的”或“意图”这一概念本身并未被清晰界定，可作多种解释。[213] 例如，在最近一起种族选区划分（racial gerrymandering）案中，最高法院重申：“一项以歧视性意图制定的州法律”构成宪法问题。[214] 但法院所称的“歧视性意图”可能指向不同含义：是否要求证明重新划分选区的立法者憎恨或惧怕非裔美国人？抑或他们只是接受了负面的种族刻板印象，因而认为少数族裔不值得拥有同等政治影响力？又或者，他们仅从党派角度视黑人为“非我族类”？法院并未说明上述哪种情形构成“歧视性意图”。事实上，令人惊讶的是，在近五十年的司法实践中，平等保护判例的核心术语——“意图”——始终笼罩在不确定性之中。

暂且搁置这一模糊性，在典型的平等保护案件中，“意图”与“目的”通常被用来描述特定个体的内在心理状态或信念。[215] 诚然，法院有时也会对立法机构等集体主体的意图作出推断，[216] 包括在种族选区划分挑战中。但学界普遍承认，这类案件在聚合与推断方面存在难题，因为集体主体本身并无“意图”——只有其成员才有。[217] 即便针对集体决策提出挑战，只要预设了个体意图可被聚合，就仍未脱离将“意图”视为个体信念或倾向的心理学模型。

2、将平等保护教义适用于机器学习

将平等法理移植到机器学习语境时，困难随之而来。部分困难源于现行法律适用本身的模糊性；部分则为这项新技术所特有。下文将探讨反分类规范与意图规则的适用如何引发难题，并主张：机器学习工具所引发的主要平等关切，难以被反

分类和意图导向的规则充分涵盖。

首先考虑反分类规则在训练数据中使用种族标签的情形。表面上看，该教义似乎暗示：只要政府将个人种族作为“系统输入”，即触发宪法关切。[218] 将种族作为“特征”（feature），可能被视为类似于大学招生中将其作为考量因素之一。在后者情境中，即便种族只是众多因素之一，仍会触发严格的司法审查。[219]

但这一推理可能过于仓促。机器学习中将种族用作标签，与大学招生中的使用实有区别。后者是公开且“具有分裂性”的，[220] 而前者则是技术性的，往往在实践中难以察觉。此外，“意识到种族”与“实施非法种族分类”之间存在鸿沟。政府雇员（如警察或社工）在多数情况下不可避免地意识到当事人的种族——他们直接面对的是表型证据。因此，官员单纯知晓种族并不构成宪法问题。类比而言，仅将种族作为训练数据的一个特征，或许也不应自动被视为违宪。这种纳入更应被理解为日常人际互动中对种族的视觉认知。[221] 只有当种族特征以某种宪法上相关的方式影响最终决策时，才构成问题。

那么，何为“宪法上相关的方式”？在意图语境中，法院采用“若无因果关系”（but-for causation）标准。[222] 逻辑上，这一标准也应适用于反分类挑战。将其适用于机器学习语境，要求法院判断：将种族作为特征是否为某一具体决策的“若无”原因。换言之，适用“色盲”（colorblindness）规则将引发一项潜在复杂的技术性探究——即种族或性别特征在反事实意义上的相关性。

然而，即便一个考虑种族的分类器满足了该因果要求，仍可能触及反分类教义所关注的“保护个体免受种族归类之害”。[223] 因此，它仍将触发严格审查。于是问题变为：该标准如何运作？尤其地，一个考虑种族的分类器要如何才算“严格限缩”？

由于一种名为“子群有效性”（subgroup validity）的统计现象，排除具有现实效应的特征常导致显著的准确性损失。[224] 从学习器中剔除种族可能带来准确性代价。在某些情况下，这种损失可能如此之大，以至于（从某种观点看）使用种族分类器成为必要。然而，法院从未明确界定何为“严格限缩”，也未提供任何量化指引。[226] 这种模糊性在非算法语境中已造成不确定性——法院通常回避精确定义，转而含糊其辞。相关先例涉及招生中为促进多样性而使用种族因素，法院颇为回避地表示，“严格限缩”标准“根本无法用精确指标衡量”。[227]

但在机器学习语境中，这种回避不再可行：算法设计者必须为使其分类器“去种族化”或“去性别化”所导致的准确性或福利损失赋予一个数值。更复杂的是，法官很可能认为，将数值化的准确性或福利损失作为衡量是否符合反分类规范的标准，与宪法精神格格不入——近乎配额制（quota）——从而拒绝整个评估框架。

就此而言，将反分类规则适用于机器学习将产生前所未有的新难题。

意图标准的适用同样棘手。[228] 当然，机器学习工具的设计者可能怀有平等保护法意义上的歧视目的。但我尚未听闻任何可信指控称工具设计者存在此类恶意。

此外，基于意图而非分类提出的种族或族裔少数群体歧视诉讼，历来极难胜诉。[229] 即便涉事官员曾公开反复表达非法动机，亦是如此。[230] 若无通过证据开示或证词获得的“确凿证据”（smoking gun），证明违宪意图的任务将尤为艰巨。尤其当挑战基于某项技术形式的选择或特定训练数据集的采用时，原告（尤其是少数族裔成员）将面临 uphill battle（艰难处境）。[231]

在未使用非法分类的前提下，主张意图的原告可能辩称：某特征被选择是因为其“不足以充分评估受保护群体成员”。[232] 或者，他们可能试图证明：某些特征（单独或组合）被刻意选为“群体身份的代理变量”（proxies for class membership）。[233] 但我怀疑，此类论点在证明意图方面很少具有说服力。

此外，在政府部署机器学习的诸多领域（如公共福利与刑事司法），种族与性别很可能与训练数据中其他常用特征（如邮政编码或社会经济结果）高度相关。[234] 当存在现成的种族或性别代理变量时，怀有歧视意图的政府实体可通过纳入这些特征，确保不利群体获得更负面的结果。[235] 例如，在刑事司法应用中，“有大量机会将某些社会类别与统计规律、刻板印象及过往歧视关联起来”。[236] 由于这种共线性（collinearity），即使分类器未将种族作为训练特征，也可能“习得对某些社会标签（包括种族）的负面关联”。[237] 换言之，歧视性与非歧视性分类器可能外观相似。借助适度的预见性，蓄意歧视者可轻易规避责任。这一问题虽非机器学习独有，但可用特征的巨大多样性可能使其更为严重。

简言之，在缺乏“确凿证据”的情况下，适用反分类与意图教义将引发复杂的证明难题、专家间关于技术决策目的的争论，且鲜有简单解决方案。

3、对机器学习与平等的再思考

然而，许多针对机器学习提出的平等关切，并不契合反分类或意图的论述框架。它们反而提示我们需要一种替代性的规范路径。

对机器学习分类器的常见担忧在于：其有能力将人类偏见、盲点或其他规范上令人不安的假设或规律——源自训练数据、结果变量或其他设计维度——编码进系统。[238] 例如，2013 年一项研究显示，在谷歌搜索典型黑人姓名时，近 90%的情况下会出现犯罪记录广告；而搜索典型白人姓名时，同类广告出现率不足 25%。[239] 2019 年另一项研究发现，一种广泛用于推荐高风险患者护理方案的商业工具，对风险相当的黑人与白人患者给出截然不同的预警率。[240] 结果，黑人患者尽

管罹患重症风险很高，却获得较少干预。研究指出，差异源于该工具将“医疗支出”作为结果变量。

另需注意，某些人脸识别工具对黑人女性的错误率比对白人男性高出 34.7%。[24 1] 上述平等关切均难以被理解为对特定分类使用或设计者意图的担忧。或许并不意外，庞大的算法偏见技术文献也普遍回避这些概念。[24 2]

从这些案例可归纳出几类在机器学习语境中可预见、却难以纳入现有意图或反分类教义的平等相关错误。值得强调的三种是：样本偏差（sample bias）、特征偏差（feature bias）与标签偏差（label bias）。[24 3]

样本偏差源于非随机抽样构建训练数据。例如，阿勒格尼县 AFST 评分系统的训练数据，可能反映了公众举报风险时的偏见——黑人家庭因较轻微违规即被纳入国家监管，而白人家庭则不然。[24 4] 结果，被标记为“有问题”的黑人家庭多于白人家庭，导致样本失真。

特征偏差发生在训练数据中的某特征因跨群体标注错误率不同而系统性失真。[24 5] 例如，在劳动力市场分析中，若因评估偏见而错误地将女性标注为“生产力较低”，即属此类。

标签偏差则出现在指定的结果变量未能对不同群体同等准确地反映“真实情况”（ground truth）之时。[24 6] 若标签在不同社会群体中以不同阈值分配，结果变量便可能对特定子群体显现偏见。例如，保释算法若以逮捕数据为训练基础，而警方对相同行为更倾向于逮捕某些种族群体，则使用此类数据作为结果变量将引入偏见。

这些问题均无法被现行平等保护教义充分涵盖。[24 7] 至少这表明：驱动后者的规范关切，未必等同于机器分类所引发的平等问题。在我看来，我们应承认：恶意意图与反分类框架，并不能为分析机器学习工具引发的平等关切提供全面或清晰的视角。

尽管在此构建一套完整的替代性平等法理超出本文范围，但我愿初步勾勒一种与现行宪法体制保持距离的、重构后的平等关切分析路径。

首先值得强调：“种族”的确切本质即便在自然科学与社会科学界仍存争议。[24 8] 但无需在此解决该争议，我们仍可观察到：种族之所以具有规范相关性，是因为它被负责关键分配决策的个人与机构当作一种“社会事实”加以运用。[24 9] 正因这种社会性使用，种族（如同性别与残障）已与其它劣势与排斥指标高度相关。由于种族与其他排斥性度量存在冗余编码（redundant encoding），无论是直接依赖种族还是其相关特征（如教育成果、居住邮编），往往都会强化资源与机会以

可预测的不对称方式分配的趋势。

真正应受平等规范保护免受的伤害，正是这种对历史上边缘化群体生活机会与物质福祉的系统性削弱。因此，一种合理的替代性重构路径应聚焦于：**预测驱动的福利或负担分配是否会放大种族（或性别、性取向、残障、族裔等同类分类）的社会分层效应**。（从结果上来评价，不一定从变量、规则上来评价。）

在机器学习语境中，对此类伤害的考量不能依赖机械的“反种族意识”规则，或对预测本身的一概否定。鉴于当前种族分层的深度，我认为，若不在一定程度上有意识地考量劣势如何在时空维度上传递，并适时采取种族意识干预（race-conscious interventions）以打破这些机制，预测工具恐怕难以避免此类伤害。当然，此类干预可能带来社会成本（例如提高整体人群的错误率），算法设计者必须在公平与其他目标之间作出权衡。

当然，此类权衡在政治与规范层面极具争议。但机器预测的兴起，恰恰使其尖锐化。换言之，计算预测的进步，很可能加剧“色盲”理想与构建一个“种族（或同类属性）不决定个人人生轨迹与机会集合”的社会秩序这一目标之间的冲突。

C. 隐私

隐私并非一个单一、统一的概念，而是一个多元复合体。它“复杂……交织于相互竞争甚至矛盾的维度之中，并承载着多种且迥异的含义。”[250] 本文聚焦其中一条脉络：信息隐私（informational privacy），即个人对其所持有的敏感信息在如何披露以及向谁披露方面拥有工具性的控制能力。[251] 在美国，[252] 信息隐私的判例法远不如正当程序或平等保护领域的案例那样成熟。我将简要描述其教义现状，继而探讨机器学习如何对信息隐私造成独特损害，并思考应如何构建一种更具包容性的宪法或次宪法（subconstitutional）隐私制度以作回应。

1、宪法隐私规范

最高法院从未承认过一项独立的信息隐私权。在 1977 年的 Whalen v. Roe 案中，法院仅为论证之便，假定宪法禁止政府不当收集、聚合或披露个人私密信息。[253] 尽管此后最高法院从未将《惠伦案》扩展为一项完整的宪法性信息隐私权，但一些巡回法院已在其基础上有所发展：部分法院否认此类权利存在，另一些则谨慎地制定出判断该权利是否成立的教义标准。[254] 2010 年的一项先例似乎对《惠伦案》采取了狭义解读，但明确拒绝否定宪法信息隐私权存在的可能性。[255]

此外，《卡彭特诉美国案》（Carpenter v. United States）虽在第四修正案语境下限缩了“第三方原则”（third-party doctrine），也承认了公民有权阻止政府从第三

方获取其私密信息。[256] 然而，第四修正案下的第三方原则在分析逻辑上不同于一项独立的权利——即控制从原本无害的数据中推导出私密推论的权利。

鉴于宪法层面对信息隐私的保护薄弱，有必要将目光投向联邦与州的成文法或规章。然而，次宪法层面的法律呈现碎片化状态：某些联邦法律和规章中的隐私保护适用于私人主体，却不适用于联邦或州政府机构；[257] 在州一级，加利福尼亚、纽约和马萨诸塞等州对大型企业施加了数据安全义务，却未同等约束州政府行为者。[258] 此外，“大多数州都已开展隐私执法”，但主要针对的是私人主体。[259]

因此，州法及州官员可在一定程度上弥补联邦法的缺漏。但若认为其覆盖范围是系统而全面的，而非零散且随意的，则属误判。正如 Lior Strahilevitz 在一项缜密的综述分析中指出，这种联邦与州层面的异质性意味着：一名州或联邦雇员或许能就政府未经授权披露其信息提起普通法隐私侵权之诉，但能否成功，取决于联邦侵权责任、豁免原则与州法之间复杂的互动关系。[260] 唯有对特定司法辖区适用的联邦与州法进行细致分析，才能判断某一行为是否构成隐私法意义上的违法。

2、机器学习带来的隐私风险

机器学习的运作催生了两类全新且独特的信息隐私风险。

第一类涉及国家从原本无法揭示特定私密事实的数据中推导出敏感信息的能力。这意味着“私密”信息可在未经宪法所规制的“搜查或扣押”前提下被获取。机器学习可能引发多种侵犯隐私的推论：一种是所谓“类别跃迁”（category-jumping）式推论，即“揭示个体曾明确向他人隐瞒的属性或状态”。[261] 例如，从消费数据推断健康状况，或从健康数据推断行为倾向。（从一种数据推断出另一种特征）另一种则是利用某人的数据对未出现在数据集中的他人作出推论。例如，联邦政府及全美 50 个州均建有基因数据库。[262] 这些数据库不仅用于匹配样本本身，还可用于匹配“近亲基因”。[263] 因此，它们能对从未接触刑事司法系统的个体之行为与位置作出“样本外”（out of sample）推论。类似地，GEDmatch 和 FamilyTreeDNA 等消费级基因平台拥有更大规模的基因数据池，[264] 其中一些已自愿向执法部门开放访问。可以预见，基因数据的推论潜力将在短期内进一步增强。2018 年，研究人员利用全基因组等位基因差异度量——即“多基因风险评分”（polygenic risk score）——成功对人群的教育与认知表现作出了令人印象深刻的预测。[265]

第二类隐私相关损害源于不同机制：机器学习依赖于对大规模训练数据池的利用。这些数据常由政府持有，一旦发生数据泄露，将给个体带来严重的隐私与

财产损失。例如，在宾夕法尼亚等州，官员甚至新建了数据仓库，整合多个原本分散的州级机构信息流，以服务于预测目的。[266] 数据泄露可由内部或外部的疏忽或恶意行为引发。研究表明，数据持有量越大，发生重大泄露的风险越高。[267]

数据库泄露不仅导致意外且社会不恰当的信息披露，还可能使个体遭受“身份盗用、欺诈与声誉损害的风险增加”，以及直接的“情绪困扰”。[268] 正是因为“关于隐私侵害的原因、严重程度与规模的可靠信息匮乏”，我们才难以准确评估问题的严重性及现行法律应对是否充分。[269] 可以合理推测，机器学习在政府职能中的广泛扩散，将进一步加剧此类隐私损失风险，其程度甚至超过私人主体收集与分析个人数据所带来的风险。

3、机器学习国家中的隐私权

机器学习可能引发的信息隐私损害具有多样性与复杂性，这排除了在该语境下存在单一“隐私权”的可能性。与其视为一项统一权利，不如将隐私理解为一组以维护适当数据流动为核心关切的权利集合。在此语境下，隐私不能简化为个体对信息的绝对控制权；[270] 后者仅是应对策略组合中的一部分。我将探讨三种路径——禁令（prohibitions）、零售式控制权（retail control rights）与**“设计内嵌隐私”**（privacy by design）——并认为尽管后者存在局限，但可能是最有前景的方案。

第一种应对选项体现为旧金山对人脸识别工具的预防性禁令，即完全禁止收集和使用特定类型的数据。[271] 然而，我对在人脸识别领域实施信息获取限制的有效性持怀疑态度。尤其当私人监控持续存在时，仅禁止公共监控很难有效解决此类工具引发的隐私忧虑。2016 年，美洲地区的视频监控产业估值已达 39 亿美元。[272] 同年，约 60%售出的摄像头具备联网功能，其中 40%内置视频分析模块，“用以自动化监控流程，并能有效主动识别事件或从录像中提取信息”。[273] 即便如旧金山般政府弃用此类工具，私人主体仍将积极构建数据库并推进基于识别的推论。一旦私人使用足够普遍，公众很可能认为政府禁令显得荒谬且多余——尤其在发生高关注度犯罪或暴力危机之后。

然而，在其他领域，对数据收集或推论的类别性禁令可能更为有效。自 2008 年起，《基因信息非歧视法案》（GINA）禁止保险公司与雇主在承保或招聘决策中使用基因数据。[274] 由于“典型的 GINA 诉讼”发生于保险公司“因基因检测揭示未知健康风险而取消承保或大幅提高保费”之时，该法最好被理解为对从孤立看无意义的数据中进行**推论性剥削**的预防措施。[275] 因此，基于隐私理由或基于“某些预测不应属于政府职权范围”的立场，禁止特定类型的机器学习推论

或许是正当的。例如，GINA 可被解释为体现了一种理念：生物学不应被国家视为命运。[276]

另一方面，类似禁令很难延伸至政府行动，因为有证据表明，建立 DNA 数据库与谋杀、强奸等严重犯罪率的显著下降相关。[277] 当存在可抵消隐私损失的其他社会利益时，禁令可附带“日落条款”（sunset clauses）——此类临时措施允许监管者观察技术应用效果、评估其收益是否大于成本，并探索减轻损害的途径。

第二种替代方案是赋予个体更精细的零售式权利，以挑战特定推论。此类使用规制已在外国情报领域存在，[278] 学者也更广泛地主张将其作为监管政府数据库的手段。[279] 然而，在采纳以分散个体诉讼为基础的监管改革前，需保持谨慎。一方面，依赖个体许可来授权机器推论的救济框架，未能考虑官员可能通过跨多次查询聚合信息而制造新型隐私侵害。例如，仅搜索某人行踪的视频数据或许不构成严重侵犯，但若同时掌握其网络元数据，则可能构成重大隐私入侵。因此，细粒度的搜查令制度可能遗漏由信息聚合所催生的重要效应。[280] 更一般而言，在刑事司法领域，事前审查机制（ex ante screens）并未被证明能持续有效约束官员裁量权。[281] 现代刑法体系的庞杂降低了获取搜查令的成本。同样，对机器学习推论的规制也可能面临政府行动正当性理由的“实质膨胀”（substantive inflation）。鉴于第四修正案的搜查令规则在刑法实质扩张面前已显乏力，[282] 我们没有理由对机器学习这一更不显眼领域的事前审查机制抱持乐观。相反，当前刑事搜查中个体化事前审查机制的薄弱，恰恰提示我们在机器学习语境中需要一种更系统性的方法。

此外，零售式隐私权的另一问题是：个体似乎是保护工具的极不完美使用者。隐私损害的独特之处在于，其往往在信息披露很久之后才显现。零售式隐私权预设个体能预见并权衡时间上分离的损害，但这一点并不确定。多项研究发现，人们在合同情境中对隐私权的估值存在显著差异，这种差异似乎受“禀赋效应”（endowment effects）[283] 或“非理性地愿意牺牲隐私以换取眼前便利，从而在未来形成‘可能永久的负面年金’”[284] 所驱动。即便平台与商家通过在线交易获取的数据具有巨大经济价值——据估计，2017 年美国互联网平台从消费者个人信息中获得 638 亿美元价值，2018 年达 760 亿美元[285] ——此类认知偏差依然普遍存在。

第三种超越禁令与零售控制的路径，是将隐私关切直接内嵌于机器学习工具的架构之中，即“设计内嵌隐私”（privacy by design）。目前存在一系列 loosely defined（宽泛界定的）“最佳实践”准则，要求将隐私“嵌入信息系统的设计与架

构之中”。[286] 政府可直接实施此类方案，也可委托处理敏感数据的私营主体执行。[287]（信息处理者的义务）

顾名思义，“设计内嵌隐私”在系统层面运作。例如，一项网络安全分析强调需采用“灵活且模块化”的数据存储架构；[289] 另一研究则列举了若干“旨在检测并防止未经授权访问、使用或传输机密信息的系统”。[290] 具体措施包括：按敏感度对数据分类、通过加密与权限控制直接管理访问、将高度敏感数据分散存储于隔离的“数据孤岛”中，以防单次泄露造成过大损害。[291] 当信息分布于众多物理设备（如监控摄像头或 Rapid-DNA“拭子进-档案出”设备[292]）时，通过事后打补丁实现安全防护既困难又不可行，必须在设计与建造阶段就集成安全机制。[293] 核心观点再次明确：无论涉及集中式数据库还是分布式设备网络，隐私都必须在设计阶段硬编码（hardwired），而无法在后端有效补救。它更类似于分权制衡等宪法结构性安排，而非一项离散的个体权利。[294]

当然，“设计内嵌隐私”并非万能良药。Deirdre Mulligan 与 Kenneth Bamberger 在近期一项调查中指出，在认知偏见与意外后果的影响下，“有意将价值观转化为设计要求”极为困难。[295] 他们认为，问题根源在于实现“设计内嵌隐私”的政府流程存在缺陷：

“现有民主与行政治理的制度与流程已被证明是拙劣的‘设计战场’。它们在结构上不适合进行治理所需的那种审议式决策。国内尚无平台就‘在何种情境下嵌入何种价值观’展开广泛对话。行政程序往往甚至未能将技术设计选择视为公共政策问题，而仅视作私人选择或政府采购事项。各机构普遍缺乏必要的技术专长与法定授权，无法充分考量将价值观嵌入设计的深远影响……逐个机构的决策模式会引发下游涟漪效应，优先某些价值观而排除对其他价值观的审慎讨论。先行者——尤其是对私营部门影响力最大的那些机构——可能将技术工具化，服务于其特定使命。”[296][18]

为回应这些关切，他们提出一系列最佳实践以缓解制度性病理。[297] 其缜密分析表明：负责实施“设计内嵌隐私”的机构与部门，亟需经过精心的制度设计。

总之，信息隐私——如同正当程序与平等一样——需通过对机构层级系统的审慎设计与持续维护来实现。它是机器学习工具运行所依托的整体信息架构的属性，而非任何单次分类或预测行为的产物。无疑，随着技术演进——从 PC 应用到手机工具，再到物联网（甚至可能迈向脑机-AI 融合[298]）——最适合促进隐私的

[18] See Deirdre K. Mulligan & Kenneth A. Bamberger, Saving Governance-by-Design, 106 CALIF. L. REV. 697, p.701-702 (2018). For criticism of “privacy by design” as ambiguous and an inappropriate delegation of authority to (unrepresentative) engineers, see Ari Ezra Waldman, Privacy’s Law of Design, 9 U.C. IRVINE L. REV. 1239, 1273 & n.229 (2019)

具体工具必将变化。但可以合理预期，以系统层级为重心的隐私响应型政策制定模式将持续存在。

D. 机器学习的宪法规范：小结

本部分旨在探讨正当程序、平等与隐私等核心宪法价值如何在“机器学习国家”（machine-learning state）中被提出并受到挑战。这些规范的适用不仅涉及非算法语境下人们熟悉的难题，更引发了一系列新型问题。针对每一项权利，我都提出了对该相关规范的一种重新校准的理解（recalibrated account）。在结尾处，我想强调贯穿上述分析的一条共同主线：

当人类与算法系统互动时，规范性关切往往并非源于特定互动的具体细节，而是源于影响众多乃至全体用户的结构性或设计性决策。换言之，正当程序、平等与隐私等宪法规范，在机器学习语境中普遍地在系统层面而非个体层面发挥作用。尽管在某些非算法情境中亦有类似现象，但机器学习国家中宪法规范的这种系统性特征（systematicity），构成了一个强有力的理据，促使我们摆脱目前主导宪法权利司法救济的“侵权责任模式”（liability in tort model）。

采取一种系统性、整体性（systematic and wholesale）而非零售式、个体化（retail and individualistic）的视角来理解算法时代的宪政主义，其正当性可从诊断（diagnosis）、因果机制（causation）以及（与下一部分密切相关的）救济（remedy）三个维度加以阐明。

首先，从诊断角度看，个别错误决策案例的出现，并不能充分证明某一算法分类系统已偏离正当程序规范。同样，某项分类规则倾向于对受保护群体成员与非成员作出不同排序，这一事实本身也不足以说明存在平等权问题。[29 9]

其次，就因果机制而言，**正当程序、平等与隐私侵害的根源通常在于系统的设计与运行方式，而非一线官员（street-level official）孤立、离散的行为**。若不采取系统性视角，不去审视嵌入算法训练数据、结果变量与方法中的整套人类设计决策，往往难以识别错误或系统性偏见究竟如何产生、为何发生。同理，数据泄露风险也通常源于信息系统架构本身的薄弱环节。

最后，就救济而言，**若缺乏系统性视角，针对正当程序、平等与隐私问题的补救措施很可能是不完整的。例如，允许个人对算法决策提出人工申诉，或许能在个案中满足正当程序要求，却可能提高整体错误率；**[30 0] **同样，简单地从算法特征集中剔除种族变量，也可能导致错误率急剧上升。**[30 1]

正是由于正当程序、平等与隐私关切根植于系统层面，我们的注意力被引向

那些在时间上远离“机器与受规制个体直接接触”的人类决策与算法设计要素。这一转向进而提出了新的实践问题：在当前以“侵权责任模式”为主导的宪法权利执行框架下，[30 2] 这些规范应如何被切实落实？这些问题将在下一部分得到更深入的探讨。

III. 机器学习国家中的宪法救济

一个针对“机器学习国家”（machine-learning state）量身定制的救济架构应包含两个要素：

第一，事前规则（ex ante rules），一方面强制披露、提升透明度，另一方面施加旨在增强准确性、隐私保护与平等性的实质性要求；

第二，事后提供聚合性（aggregate），而非仅限于个体化的诉讼救济。

在其他研究中，我曾反对将“获得人工复审的权利”视为对预测工具中宪法缺陷的适当回应。[30 3] 基于此前文章所发展的论点，我在此主张：**聚焦预测工具系统性特征的聚合性救济（aggregate remedies）**，能更有效地识别并纠正那些引发宪法错误的设计选择。

本文所采用的分析框架借鉴了法学中一个经典区分：规则（rules）——其内容在事前即已确定；与标准（standards）——其内涵需在事后具体情境中加以填充。[30 4] 在实践中，这种事前/事后之分虽不完全对应，但大致关联着两种规制模式的选择：行政机构规制 vs. 通过侵权责任普通法体系进行规制。[30 5] 为简化论述，此处假设事前规制由行政机构实施，而法院负责事后审查。

这两种干预方式各有优势。事前规制倚重官僚体系的专业知识、可预测性与一致性；[30 6] 事后干预则通过迫使行为人内化潜在损害赔偿，赋予私人主体自主选择空间，并允许“各方根据预期调整其救济措施”。[30 7] 尽管部分学说将二者视为互斥选项，实践中“事前与事后政策常被联合使用”。[30 8] 特别是，事前规则的颁布可有效缓解事后行为主体面临的不确定性。[30 9]

在机器学习语境下，事前规制可提供现成的模板，用于规范披露义务、设定透明度标准，并对隐私与平等价值提出设计层面的要求。这些措施有助于降低事后不确定性，并为事后的诊断与问责奠定基础。然而，仍需辅以事后审查，以确保宪法性设计决策已被采纳，且工具未因“脆弱性”（brittleness）而导致准确性下降。

即便承认需通过诉讼进行事后执行，关于诉讼监督形式的问题依然存在。此处我强调：聚合性诉讼（aggregate litigation）优于针对个案结果的“零售式挑战”

（retail challenges）。聚合性挑战（如集团诉讼、面部挑战〔facial challenges〕[19]等）能有效引导关注点转向造成宪法损害的系统性根源。其所催生的救济方案，会考虑所有受规制对象的整体利益——而非仅改善部分群体的准确性，却以牺牲多数人为代价。尽管聚合/零售之分并非救济设计中唯一重要的考量（也非此语境独有），但鉴于其在机器学习背景下的特殊重要性，我在此予以聚焦。

A. 算法规制

行政机构长期以来都是“负责落实国会立法指令的关键行动者”。[310] 相较于立法者与法院，机构在专业知识与响应能力方面具有比较制度优势。[311] 事前规制可由联邦及地方层级的机构共同推进。例如，加州已通过隐私保护立法，将影响私人主体部署机器学习的方式；[312] 西雅图与圣克拉拉等城市则出台了涵盖监控数据收集与分析全过程的法规。[313] 此类实践不太可能是孤例；相反，在缺乏联邦统一行动的情况下，跨辖区的政策扩散、模仿与竞争很可能催生活跃的监管创新。

事前规制可分为两类：实质性标准与披露机制。下文将分别探讨。

1、实质性监管干预

在非公共领域，与机器学习最相关的常见事前干预是“设计内嵌隐私”（privacy by design）。欧盟与美国联邦政府均已采纳此类强制要求。[314] 学界亦投入大量精力完善其原则。[315]

本文则聚焦于平等规制。这一焦点具有现实意义：当前监管过度强调隐私，反而使平等价值的执行成本上升——因为隐私保护常剥夺监管者与私人方识别歧视现象所必需的信息。[316] 例如，伊利诺伊州 2019 年一项法律要求，在求职者提出请求后，用于招聘决策的视频数据须在 30 日内销毁。[317] 此举虽保护隐私，却极大增加了事后查明招聘过程中是否存在非法歧视的难度。

因此，当立法者与机构考虑如何管理公共部门对机器学习的使用时，应更加重视构建有利于实现平等价值的计算基础设施。本着这一精神，本节提出一项与平等相关的监管干预：强制采用“最佳可行”（best feasible）。需预先说明，此理念不仅适用于平等，也可延伸至正当程序与隐私领域。

值得探索的一项监管方案，可类比联邦环境法中广泛采用的“最佳可用技术”（Best Available Technology, BAT）规则。[318] 其核心思路是：监管机构可对算法施加 BAT 要求，强制其采用“非歧视性”（公平）的设计（该逻辑亦可用于防

[19] 主张法律在字面上就违宪了，要求其无效的诉讼。

范数据泄露的安全规制）。

例如，《清洁水法》授权环保署（EPA）在确定“最佳可行控制技术”时，需综合考量“技术应用总成本与预期污染物削减效益之比”、“设备与设施的年限”、“所用工艺”、“各类控制技术的工程特性”、“工艺变更”以及“环境影响”等因素。[319] 此类 BAT 规则使机构能基于行业实践分布，推导出适当的监管标准。[320] 更贴近本文语境的是，BAT 规则甚至被提议作为网站版权执法责任的判定基准。[321]

BAT 规则可通过多种方式实施：

可制定宽泛要求，将负担转移给受规制方，促使其选择或开发能最小化种族/性别相关成本、或最大化特定公平结果的工具。法院则在事后诉讼中判断何为 BAT。此路径承认受规制方在优化成本收益方面更具优势。

或由机构事前公布一份“最佳可用技术清单”，供受规制实体从中选择。[322] 这要求机构提前识别促进平等的创新，信息来源可包括观察私营市场行为，或通过奖金、研究资助等信息披露机制获取。[323]

第三种可能是在分类器方程中直接嵌入一个“平等项”（equality term）。[324]

当然，无论采取何种路径，机构都需事先界定其所重视的平等形式（如种族或性别平等），尽管具体技术设计负担可能有所不同。

总之，此类 BAT 强制令展示了可用于激励事前良性算法行为的实质性规制工具。此例并非穷尽式方案，而是意在激发更多监管可能性的想象。[325]

2、透明度与披露义务

另一类事前规制路径聚焦于各类“透明度”与“可解释性”(explainability) 要求。首先需谨慎指出：透明度概念本身含义模糊，且可能带来成本。随后将探讨如何化解这些难题，最后列举若干虽不严格属于“透明度”范畴、却能促进事后宪法判断的具体披露义务。

尽管“可解释人工智能”（XAI）近年复兴，但“可解释性”及其近义词“透明度”的确切含义仍存激烈争议。[326] 有批评指出，“可解释性”实为一个“行李箱词汇”（suitcase word），囊括多种含义却无普遍共识。[327] 一个关键歧义在于：披露义务的对象究竟是“模型运作机制”，还是“特定分类决定的理由”？[328] 前者属全局解释（global explanation）——提供描述算法运作的普适规则；后者属局部解释（local explanation）——聚焦具体实例。[329]

大众论述常假定机器学习必然不可理解。[330] 确实，许多架构（如深度学习模型）极为复杂，其计算逻辑难以用非技术语言传达。以 2015 年微软开发的 ResNet 为例：该卷积神经网络含 152 层，且采用“跳跃连接”（skip-connections），

使外层神经元可直连深层结构。据记载，向非专业人士“解释”ResNet 如何得出特定结果几无可能。若将“透明度”理解为要求向普通人清晰说明此类模型的内部运作，则无异于徒劳。

但 ResNet 未必代表当前政府常用模型。认为所有机器学习模型都如 ResNet 般不可穿透，实属误解。决策树、线性模型等方法对人类而言“更易理解与解释”。[333] 因此，全局可解释性的程度，实为算法方法选择的函数。当前最先进（因而最有效）的深度学习工具，因其规模庞大、采用分布式表征及迭代计算，最难被直观呈现。[334] 尽管学界正研究通过可视化等工具提升其可理解性，[335] 但聚焦特定方法运作机制的全局透明度要求，往往需在透明度与准确性之间权衡。有时此权衡可避免——例如寻找性能接近复杂模型但更易理解的“简单规则”。[336]

在上述约束下，对分类结果的解释（如“为何此人被羁押，彼人福利被拒？”）可采取不同路径。与全局解释类似，结果解释的可行性亦取决于其概念化方式：

可从设计目标出发：“x 结果因算法旨在实现 p 而产生”；

可指向技术架构细节（如超参数校准方式）；[337]

或采用因果解释——但机器学习推论多为相关性而非因果性，此路径可能受阻。

相较之下，近期研究指出：用户最常诉求的是“对比性解释”（contrastive explanations）——即不解释事件本身的成因，而解释“为何发生 x 而非 y”。[338] 此类解释需识别反事实情境：仅改变最少特征即可导致不同分类，或揭示结果与某项政策判断/潜在变量的关联。[339] 此类透明度在许多场景下是可实现的设计选项，但具体机制的选择，应取决于算法决策在特定语境中引发的规范性问题。[340]

除上述针对决策的解释外，还可设定更具体的披露义务以支持事后问责。兹举三例：

数据表（Datasheet）：算法决策应附带记录训练数据的选择与处理方式，以及“数据构成、采集过程、推荐用途”等信息。[341]

可审计性设计（Auditability）：算法应设计为允许第三方“探测与审查其行为”。[342] 最基本方式是提供应用程序接口（API），使外部可在不接触底层算法的情况下进行下游审查。[343]

加密承诺与区块链日志：将加密承诺嵌入代码，确保对所有受规制对象适用相同决策规则。[344] 伦敦帝国理工学院与 MIT 媒体实验室的“开放算法”（Open Algorithms）项目进一步提出：利用区块链记录算法在各案例中的使用方式。[345]

类似设计还可要求算法生成“防篡改记录”，提供“不可否认的各节点行为证据”。[346]

上述披露不应受算法开发者“商业秘密”主张阻碍。[347] 监管机构应强制公开某些参数与超参数。出于正当程序目的，披露内容可包括：训练数据的性质与来源、从数据中可习得规则的约束条件、结果变量及潜在构念。鉴于保护令（protective order）的存在，此类披露几乎不会实质性侵害算法设计的知识产权。即便供应商以知识产权为由拒绝，监管者仍有充分理由强制其公开足够细节，以阐明历史数据如何转化为预测或处方。机构不仅有权将此类披露作为获得政府合同的前提，还可援引知识产权法本身所蕴含的“促进公开”宗旨。[348]

小结

由于关乎宪法规范的决策常内嵌于机器学习系统的初始开发与设计阶段，监管者处于有利位置，可制定促成合宪性合规的强制要求与约束。我的分析表明：监管者拥有丰富的事前工具箱，可用于在机器学习国家中推动宪法价值。此处提出的分类并非规制设计的终极指南，而是迈向构建必要监管框架、以实现法治下的机器学习国家的第一步。

B. 算法合宪性的诉讼

事前规制对于在机器学习国家中推动宪政主义必要但不充分。机器学习系统的设计者无法事先确知其工具在所有可设想情境下的表现。习得的规则在面对意外现象时常常表现出“脆弱性”（brittleness）。[349] 即便受严格的事前规制约束，设计者仍可能未能安装或维持对宪法规范（如正当程序、平等、隐私）的适当保护——例如，隐私保护补丁未及时部署、硬件老化未被缓解，或结果变量与所关注的潜在构念之间出现偏差。因此，即便存在事前规制，某种形式的事后诉讼（ex post litigation）仍是必要的。

在机器学习国家中，执行宪法规范的最优诉讼形式应是整体性（wholesale），而非零售式（retail）。它应以算法系统的整体运作为相关交易框架，提供的救济应聚焦于纠正与改进该系统的运行，而非追求损害赔偿，亦非发布绝对禁令（如全面禁止机器学习），更不应仅允许特定原告“退出”系统而不顾及大多数受规制者的待遇。[350] 换言之，此类诉讼的抱负应被理解为：推动系统性改善，这正契合正当程序、平等与隐私等宪法规范本身的整体性特征。

针对算法治理工具提起的合宪性诉讼，必然聚焦于该工具的系统级运作：

正当程序挑战（依据 Mathews 案标准）通常围绕算法架构如何导致大量误报

（false positives）或漏报（false negatives）展开；[351]

平等权挑战（无论基于意图还是分类）核心关注训练数据、特征选择与结果变量的设定（尽管这些参数的具体分析方式尚无定论）；[352]

隐私诉讼则倾向于聚焦软硬件的系统性漏洞，以及“设计内嵌隐私”原则的缺失。[353]

某些设计层面的监管要求——如透明度义务、加密承诺、零日漏洞证明（zero-day proofs）等——可通过确保诉讼当事人可预测地获取关键经验与技术细节，从而促进诉讼开展。此外，可借鉴差别性影响诉讼（disparate impact litigation）中的举证责任转移机制，[354] 用于筛除在准确性、公平性与隐私保护三个维度上均不够稳健的设计选择。

此类宪法诉讼可由私人或公共原告提起。政府内部机构可对同级其他部门提起诉讼——此类实践在联邦[355] 与州层级[356] 均已存在。各州还拥有“国家亲权”（parens patriae）诉讼资格，可代表其“准主权利益”（quasi-sovereign interests）——即对公民福祉的“一般性关切”，这种关切本可通过州的主权立法权予以回应。[357] 当宪法利益最有效的方式是起诉与政府协作的私人主体时（如算法软件或硬件供应商因其产品对居民隐私构成不当风险），此类诉讼尤为相关。

然而，截至目前，此类诉讼尚未出现。即便未来兴起，机器学习语境下宪法规范的公共执法水平很可能仍处于不足状态。受州或联邦授权的机构有强烈动机通过内部协商解决争端，而非诉诸法院。目前，第二部分所述的正当程序、平等与隐私规范所需的制度性执法基础设施几乎完全缺失。在此真空下，私人诉讼很可能继续在捍卫机器学习国家中的宪法价值方面扮演关键角色。[358]

私人执法最显见的形式是向州或联邦法院提起集团诉讼（class action）。尽管最高法院近期限制了州法院审理全国性集团诉讼的管辖权，[359] 但州法院仍有权裁决针对州官员实施的州级政策的挑战。例如，已有诉讼成功质疑公设辩护办公室资金不足及其他刑事司法系统功能障碍。[360] 如前所述，亦已出现若干挑战机器学习在公共福利、教师评估与保释决策中应用的诉讼。[361] 正如俗语所言：“百花齐放”正当时。

这些挑战算法治理的诉讼已催生多种改革：

在休斯顿，对 EVAAS 教师评估系统的诉讼促使学区放弃算法评估；[362]

在前述阿肯色州福利系统案中，诉讼揭露“第三方软件供应商错误使用了未考虑糖尿病因素的算法版本”，并迫使州政府修正缺陷；[363]

在爱达荷州福利算法案中，原告与州卫生与福利部合作开发新模型，最终和

解协议包含一个 24 步流程，用于评估与重新校准福利分配机制。[364]–[365]

值得注意的是，上述案例均未导致损害赔偿判决，这缓解了“法律挑战将使州与市政机构承担与其过错不成比例的毁灭性责任”的担忧。[366] 这些实例表明：集团诉讼既能有效阻止在缺乏适当数据支持下使用机器学习工具，也能催化分析与重构过程——使算法得以改进而非废弃。在此意义上，诉讼部分提供了必要的激励，以持续检测算法是否偏离“真实情况”（ground truth）、消除脆弱性，并纠偏歧视等扭曲。

如同许多领域，规制与诉讼在推动机器学习国家的宪法规范方面是互补的伙伴。两者目前均处于萌芽阶段：当前无论在州或联邦层面，几乎不存在成体系的监管架构；挑战机器学习工具的诉讼也寥寥无几——尽管它们提供了有价值的“概念验证”。然而，无论是规制体系还是诉讼机制，在复杂性与能力上都远未准备好应对算法治理的持续扩散。

随着机器学习工具渗透至强制性的刑事司法系统及其监管与福利职能，建立有效的算法国家监管架构将日益紧迫。本部分已迈出第一步：勾勒出确保我们的算法国家同时成为合宪国家所必需的规制与诉讼网络的基本要素。

结语

自由宪政主义意味着对限制国家权力的承诺。当“政府的技术与军事特性及社会的生产关系”发生变革时，这一承诺便面临考验。[367] 机器学习作为一种“强大且高度可泛化”[368] 的技术，正因其有能力重塑国家与公民之间的关系而对我们的宪政体系构成挑战。

本文提出了一系列应对之策。但更广义而言，我担忧新型计算工具将增强国家分析、预测与控制其臣民行为的能力，同时削弱公民理解并反对国家强制性权力投射的能力。在极端情况下，此类技术的使用甚至可能动摇民主控制得以有效运作的必要条件。

这种机器学习国家与其主体（昔日之公民）构成了中期的重大挑战。这一挑战在中国最为尖锐且显见——各类监控与分析技术被用于压制政治异议、束缚族群与宗教认同。但我们不应幻想：同样的技术（甚至更先进的）不会在自由民主国家找到平行用途。我们也不应幻想：本文探讨的措施本身足以遏制技术威权主义（technocratic illiberalism）的蔓延。恰恰相反。此类法律反制措施，永远只是更广泛的民主努力的辅助手段——唯有后者才能防止国家与公民之间的平衡彻底倾覆。这些措施只有与公众压力相结合（如旧金山面部识别禁令所展现的那样），

在技术尚可控之时及时加以约束，方能奏效。最终，决定国家算法是否服从法治、抑或被用于驯服民主事业的，正是此类公众运动的规模与激情。